



UNIVERSIDAD FRANCISCO DE VITORIA

ESCUELA POLITÉCNICA SUPERIOR

GRADO EN INGENIERÍA INFORMÁTICA

PROYECTO FINAL DE GRADO

MODALIDAD INVESTIGACIÓN

**Análisis automatizado de resonancias
magnéticas cerebrales mediante su
modelado en grafos y aplicación de técnicas
de Deep Learning**

David Ortega Lozano

Convocatoria de Junio 2026

Director: Nombre y Apellidos del director del PFG

CALIFICACIÓN DEL PROYECTO FINAL DE GRADO

CUALITATIVA:	
NUMÉRICA:	

Conforme Presidente:	Conforme Secretario:
Fdo.:	Fdo.:

Conforme Vocal:	Conforme Vocal:	Conforme Vocal:
Fdo.:	Fdo.:	Fdo.:

Lugar y fecha: Pozuelo de Alarcón, a ____ de _____ de 202__

"All models are wrong, but some are useful."

George E. P. Box (1976, 1987)

Agradecimientos

En primer lugar, me gustaría agradecer a mi tutor, Alberto Nogales, por proponerme un reto técnico tan ambicioso y exigente. Este proyecto me ha permitido aprender enormemente, tanto a nivel técnico como en la gestión y planificación de un trabajo de esta magnitud. Aunque el desarrollo ha supuesto una dificultad considerable, su disponibilidad, orientación continua, consejos y ayuda para resolver dudas han sido fundamentales para que el proyecto haya podido alcanzar el estado actual en un periodo de poco más de cuatro meses.

También quiero agradecer a Natalia Soler por aportarme una visión más cercana al ámbito de la neurociencia. Sus explicaciones y aclaraciones sobre conceptos que desconocía me han ayudado a comprender mejor el contexto del proyecto y a afrontar con mayor seguridad algunos aspectos relacionados con la interpretación de los datos y el enfoque del trabajo.

Por último, quiero expresar mi agradecimiento a mis compañeros de trabajo Miguel Vicente por todo lo que me ha enseñado a nivel técnico y a nivel de buenas prácticas a la hora de programar, y en especial a Marino Pérez, por todo lo que me han enseñado durante este tiempo. Su forma de trabajar, sus buenas prácticas, sus consejos y su manera de afrontar los problemas han influido de forma muy positiva en mi desarrollo como programador. Además, sus enseñanzas no se han limitado únicamente al aspecto técnico, sino también a la forma de gestionar emocionalmente un proyecto complejo. Muchas de las ideas, hábitos y enfoques que he aplicado en este PFG proceden, directa o indirectamente, de lo aprendido con él, por lo que considero que este trabajo refleja también parte de esa forma de trabajar que tan bien me ha transmitido.

Resumen

Este Proyecto Final de Grado presenta el desarrollo de una ampliación de la librería EEGraph para permitir el análisis automatizado de resonancias magnéticas funcionales mediante su transformación en grafos cerebrales. El trabajo parte de una revisión del estado del arte sobre neuroimagen, conectividad cerebral, representación mediante grafos y modelos de Deep Learning, y plantea una metodología orientada a construir un flujo completo desde la carga de fMRIs hasta la generación de matrices de conectividad, grafos, visualizaciones y resultados experimentales. Para validar la propuesta se utilizaron datasets abiertos de sujetos con enfermedad de Parkinson y controles sanos, aplicando preprocesamiento, filtrado y entrenamiento de una red neuronal de grafos. Los resultados permiten validar técnicamente la prueba de concepto, aunque no constituyen una herramienta clínica cerrada. Además, la memoria analiza la planificación del proyecto, sus limitaciones, implicaciones éticas, riesgos, conclusiones y posibles líneas futuras.

Palabras claves

fMRI, grafos, conectividad cerebral, Deep Learning, GNN, Parkinson.

Abstract

This Final Degree Project presents the development of an extension of the EEGraph library to support the automated analysis of functional magnetic resonance imaging through its transformation into brain graphs. The report starts with a review of the state of the art in neuroimaging, brain connectivity, graph-based representations and Deep Learning models, and proposes a methodology aimed at building a complete workflow from fMRI loading to the generation of connectivity matrices, brain graphs, visualizations and experimental results. To validate the proposal, open datasets containing subjects with Parkinson's disease and healthy controls were used, applying preprocessing, filtering and the training of a graph neural network. The results validate the proof of concept from a technical perspective, although they do not constitute a clinically validated diagnostic tool. The report also analyzes project planning, limitations, ethical implications, risks, conclusions and possible future lines of work.

Keywords

fMRI, graphs, brain connectivity, Deep Learning, GNN, Parkinson.

Índice de Contenidos

1. Introducción	11
2. Estado del Arte	13
2.1. EEGraph como Punto de Partida	14
2.2. Aplicación de Inteligencia Artificial a Resonancias Magnéticas	14
2.3. Preprocesamiento y Representaciones Intermedias de Resonancias Magnéticas	15
2.4. Representación Mediante Grafos y Modelos Basados en GNN	16
2.5. Limitaciones de los Trabajos Existentes y Aportación del PFG	17
3. Objetivos	19
3.1. Objetivo general	19
3.2. Lista de objetivos específicos	19
3.3. Métodos de Validación	19
4. Metodología y Plan de Trabajo	21
4.1. Materiales y recursos	21
4.1.1. Recursos de Software	21
4.1.2. Recursos de Hardware	21
4.1.3. Datos y Recursos Externos	22
4.1.4. Recursos Humanos	22
4.1.5. Metodología	23
4.2. Métodos	23
4.2.1. Enfoque metodológico del trabajo	23
4.2.2. Diseño del método de transformación de fMRI a grafos	24
4.2.3. Selección y caracterización de los datasets	27
4.2.4. Construcción del dataset de grafos para la prueba de concepto	27
4.2.5. Diseño y desarrollo de la prueba de concepto con GNN	28
4.2.6. Criterios de evaluación	29
4.3. Plan de Trabajo	30
4.3.1. Plan de Trabajo Inicial	30
4.3.2. Plan de Trabajo Final	30

4.4.	Condicionantes y Limitaciones.....	31
5.	Resultados.....	33
5.1.	Objetivo 1: Estudio de datasets abiertos disponibles.....	33
5.2.	Objetivo 2: Transformación de fMRI en grafos.....	35
5.2.1.	Flujo de transformación de fMRI a grafo	36
5.3.	Objetivo 3: Preprocesamiento de los datos de entrenamiento	40
5.4.	Objetivo 4: Entrenamiento de modelos de Deep Learning	41
5.5.	Objetivo 5: Evaluación cuantitativa del rendimiento del modelo	43
5.6.	Objetivo 6: Integración de los módulos en una librería funcional.....	47
5.7.	Valoración global de la prueba de concepto	48
6.	Implicaciones Éticas e Impacto Social	51
6.1.	Introducción	51
6.2.	Marco Ético y Legal	51
6.3.	Valor del Proyecto	52
6.4.	Alcance del Proyecto.....	52
6.5.	Responsabilidad e Impacto	52
6.6.	Conclusiones	53
7.	Mi Recorrido en la UFV.....	55
7.1.	El PFG como culminación de mi camino universitario.....	55
7.2.	Vinculación con mi futuro profesional.....	56
8.	Conclusiones	59
9.	Otros Méritos del Proyecto	61
10.	Bibliografía	63
Anexo A:	Detalle de Datasets Utilizados.....	67
	Neurocon.....	67
	OpenNeuro.....	67
10.1.1.	OpenNeuro ds005892	67
10.1.2.	OpenNeuro ds004718	67

10.1.3. OpenNeuro ds004392	67
10.2. Reparto de datos	68
Anexo B: Plan de Trabajo	69
Plan de Trabajo Inicial.....	69
PT1.....	70
PT2.....	72
PT3.....	73
PT4.....	74
PT5.....	75
PT6.....	76
Plan de Trabajo Final	77
PT1.....	77
PT2.....	77
PT3.....	77
PT4.....	78
PT5.....	78
PT6.....	78
Anexo C: Registro de Riesgos	79
Anexo D: Preprocesamiento Prueba de Concepto.....	83
Lectura del archivo JSON sidecar y extracción del TR.	83
Estandarización geométrica entre fuentes.	83
Normalización global de intensidad.	83
Spatial smoothing.	84
Detección de outliers para control de calidad.	84
Regresión de confounds reales.	84
Scrubbing.	84
Filtrado temporal band-pass.	85
Relación con la librería fmrip y alcance real del preprocesamiento aplicado.	85
Anexo E: MODELO DE DECLARACIÓN DEL USO DE SISTEMAS DE IA .	87

Índice de Tablas

Tabla 1: Recursos Creados para el Gantt del Plan de Trabajo. Fuente: Elaboración propia.	30
Tabla 2: Distribución inicial de muestras tras el filtrado 116x116. Fuente: Elaboración propia.	34
Tabla 3: Distribución final de muestras tras el balanceo por dataset. Fuente: Elaboración propia. ..	34
Tabla 4: Función de los módulos más importantes. Fuente: Elaboración propia.	35
Tabla 5: Resultados de la transformación de fMRI a grafo. Fuente: Elaboración propia.	39
Tabla 6: Salidas generadas por preprocesamiento_gnn_fmri.py. Fuente: Elaboración propia.	41
Tabla 7: Combinación final de hiperparámetros. Fuente: Elaboración propia.	42
Tabla 8: Resultados finales de la GNN. Fuente: Elaboración propia.	43
Tabla 9: Matriz de confusión del conjunto de test. Fuente: Elaboración propia.	43
Tabla 10: Métricas derivadas de la matriz de confusión. Fuente: Elaboración propia.	43
Tabla 11: Distribución de train, eval y test. Fuente: Elaboración propia.	44
Tabla 12: Resultado de la validación cruzada con k = 5. Fuente: Elaboración propia.	46
Tabla 13: Flujo funcional integrado en la librería. Fuente: Elaboración propia.	48
Tabla 14: Valoración global de la prueba de concepto. Fuente: Elaboración propia.	49
Tabla 15: tabla resumen objetivo por objetivo. Fuente: Elaboración propia.	50
Tabla 16: Matriz de Riesgos del proyecto. Fuente: Elaboración propia.	53
Tabla 17: Muestras en bruto por dataset. Fuente: Elaboración propia.	68
Tabla 18: Muestras tras filtrado de 116x116. Fuente: Elaboración propia.	68
Tabla 19: Jerarquía de los Paquetes de trabajo (PT) del plan inicial. Fuente: Elaboración propia.	70
Tabla 20: Detalle del paquete de trabajo PT1 del Plan de Trabajo Inicial. Fuente: Elaboración propia.	71
Tabla 21: Detalle del paquete de trabajo PT2 del Plan de Trabajo Inicial. Fuente: Elaboración propia.	72
Tabla 22: Detalle del paquete de trabajo PT1 del Plan de Trabajo Inicial. Fuente: Elaboración propia.	73
Tabla 23: Detalle del paquete de trabajo PT4 del Plan de Trabajo Inicial. Fuente: Elaboración propia.	74
Tabla 24: Detalle del paquete de trabajo PT5 del Plan de Trabajo Inicial. Fuente: Elaboración propia.	75
Tabla 25: Detalle del paquete de trabajo PT5 del Plan de Trabajo Inicial. Fuente: Elaboración propia.	76
Tabla 26: Registro de Riesgos del proyecto. Fuente: Elaboración propia.	81

Índice de Figuras

<i>Figura 1. Comparativa entre el análisis de RM tradicional (CNN) y el propuesto mediante grafos (GNN). Fuente: Gemini [2].....</i>	<i>13</i>
<i>Ecuación 1: Representación generada como grafo. Fuente: Elaboración propia</i>	<i>25</i>
<i>Ecuación 2: Correlación de Pearson. Fuente: Elaboración propia.....</i>	<i>25</i>
<i>Ecuación 3: Correlación Cruzada. Fuente: Elaboración propia.....</i>	<i>25</i>
<i>Ecuación 4: Correlación Cruzada Corregida. Fuente: Elaboración propia.....</i>	<i>26</i>
<i>Ecuación 5: Matriz de Conectividad. Fuente: Elaboración propia.....</i>	<i>26</i>
<i>Figura 2. Representación con perspectiva axial y coronal de un fMRI transformado a grafo usando la librería desarrollada. Fuente: Elaboración propia.....</i>	<i>26</i>
<i>Figura 3. Plan de Trabajo Inicial completo. Fuente: Elaboración propia</i>	<i>30</i>
<i>Figura 4. Plan de Trabajo Final completo. Fuente: Elaboración propia</i>	<i>31</i>
<i>Figura 5: Matriz de confusión. Fuente: Elaboración propia.</i>	<i>44</i>
<i>Figura 6: Curva de accuracy. Fuente: Elaboración propia.</i>	<i>45</i>
<i>Figura 7: Curva de f1-score. Fuente: Elaboración propia.</i>	<i>45</i>
<i>Figura 8: Curva de AUC. Fuente: Elaboración propia.</i>	<i>46</i>
<i>Figura 9. Plan de Trabajo Inicial - PT1. Fuente: Elaboración propia</i>	<i>71</i>
<i>Figura 10. Plan de Trabajo Inicial - PT2. Fuente: Elaboración propia</i>	<i>72</i>
<i>Figura 11. Plan de Trabajo Inicial - PT3. Fuente: Elaboración propia</i>	<i>74</i>
<i>Figura 12. Plan de Trabajo Inicial - PT4. Fuente: Elaboración propia</i>	<i>74</i>
<i>Figura 13. Plan de Trabajo Inicial - PT5. Fuente: Elaboración propia</i>	<i>76</i>
<i>Figura 14. Plan de Trabajo Inicial - PT6. Fuente: Elaboración propia</i>	<i>76</i>
<i>Figura 15. Plan de Trabajo Final - PT1. Fuente: Elaboración propia</i>	<i>77</i>
<i>Figura 16. Plan de Trabajo Final - PT2. Fuente: Elaboración propia</i>	<i>77</i>
<i>Figura 17. Plan de Trabajo Final - PT3. Fuente: Elaboración propia</i>	<i>77</i>
<i>Figura 18. Plan de Trabajo Final - PT4. Fuente: Elaboración propia</i>	<i>78</i>
<i>Figura 19. Plan de Trabajo Final - PT5. Fuente: Elaboración propia</i>	<i>78</i>
<i>Figura 20. Plan de Trabajo Final - PT6. Fuente: Elaboración propia</i>	<i>78</i>

Lista de Acrónimos

Acrónimo	Significado
AAL	Automated Anatomical Labeling
ACT	Actividad
ACM	Association for Computing Machinery
API	Application Programming Interface
AUC	Area Under the Curve
BIDS	Brain Imaging Data Structure
BOLD	Blood Oxygen Level Dependent
CNN	Convolutional Neural Networks
CV	Cross-Validation
DVARs	Derivative of RMS Variance over Voxels
EEG	Electroencefalograma
fMRI	Resonancia Magnética Funcional
GCN	Graph Convolutional Networks
GCNN	Graph Convolutional Neural Networks
GNN	Graph Neural Networks
HTML	HyperText Markup Language
IA	Inteligencia Artificial
JSON	JavaScript Object Notation
MNI	Montreal Neurological Institute
NaN	Not a Number
NIFTI	Tipo de archivo de las fMRI. Son extensión .nii.gz
PFG	Proyecto Final de Grado
PNG	Portable Network Graphics
PT	Paquete de Trabajo
QC	Quality Control
ReLU	Rectified Linear Unit
RM / MRI	Resonancia Magnética
ROI	Región de interés / región del cerebro
SOS	Second-Order Sections
TR	Repetition Time
TR (TR X.Y.Z)	Tarea
TSV	Tab-Separated Values
UE	Unión Europea
UFV	Universidad Francisco de Vitoria

1. INTRODUCCIÓN

Para un mejor entendimiento del lector de este documento, se ha querido incluir una breve introducción, respaldada por un sanitario especialista en el ámbito neurológico, sobre los términos sanitarios mencionados y abordados en este trabajo.

El contexto general de este trabajo se sitúa en el estudio de la actividad cerebral y en las técnicas que permiten registrarla o visualizarla. Entre ellas, una de las más conocidas es el electroencefalograma (EEG), una prueba no invasiva que registra la actividad eléctrica cerebral mediante varios electrodos colocados a lo largo de la superficie de la cabeza [1]. Gracias a ello, el EEG permite observar la actividad eléctrica del cerebro en tiempo real y se utiliza con frecuencia para estudiar su funcionamiento desde un punto de vista funcional.

Otra técnica importante es la resonancia magnética (RM), que también es no invasiva. En este caso, no se centra en registrar actividad eléctrica, sino en obtener imágenes detalladas de las estructuras internas del cuerpo mediante el uso de un campo magnético potente, ondas de radio y un ordenador. En el ámbito neurológico, esta prueba permite obtener una representación estructural del cerebro con gran nivel de detalle.

Junto a ella se encuentra la resonancia magnética funcional (fMRI), que comparte la misma base tecnológica de la RM, pero añade una dimensión funcional. En lugar de ofrecer solo una imagen estructural estática, la fMRI permite estudiar pequeños cambios en el flujo sanguíneo que se producen mientras distintas regiones del cerebro están funcionando. Por ello, además de mostrar la anatomía cerebral, aporta información sobre la actividad del cerebro a lo largo del tiempo.

Una fMRI, por tanto, está en 4 dimensiones, porque es una imagen 3D del cerebro que evoluciona a lo largo del tiempo. En este trabajo, para llevarlo a una representación 3D en forma de grafo, se agrupa la información por regiones del cerebro (ROIs), se asigna a cada una de ellas una posición 3D y se usa la evolución temporal para calcular las conexiones.

A partir de este contexto aparece la parte más directamente relacionada con la informática, que es la que da sentido al desarrollo de este trabajo. Las fMRI generan una gran cantidad de información y, en muchos casos, esa información no resulta sencilla de interpretar directamente, especialmente cuando se quiere estudiar la relación entre distintas regiones cerebrales, detectar patrones o utilizar los datos en modelos automáticos de análisis.

Una forma de abordar este problema consiste en representar la conectividad cerebral como una red, donde las distintas regiones del cerebro pueden modelarse como nodos y sus relaciones como conexiones. Este tipo de representación se conoce como grafo y permite trabajar con la información de una forma más estructurada e interpretable.

Además, una vez obtenida esa representación, es posible utilizarla como entrada para modelos de inteligencia artificial, que en los últimos años han demostrado gran utilidad para analizar conjuntos de datos complejos y de gran tamaño. En este proyecto, precisamente, se

plantea transformar datos de fMRI en grafos cerebrales para facilitar su análisis y permitir posteriormente su uso en modelos de Deep Learning basados en grafos. Existen las redes neuronales de grafos (GNN), las redes neuronales convolucionales de grafos (GCNN) y las redes convolucionales de grafos (GCN). Las dos últimas son esencialmente sinónimos en la mayoría de los contextos.

2. ESTADO DEL ARTE¹

El análisis de resonancias magnéticas (RM) cerebrales mediante modelos de aprendizaje profundo y aprendizaje automático, ha aumentado en los últimos años. Existen numerosos estudios que aplican modelos de Deep Learning para clasificar o analizar este tipo de imágenes. Sin embargo, en muchos casos el trabajo se limita al experimento concreto descrito en el artículo, sin ofrecer herramientas reutilizables que permitan aplicar el mismo enfoque fácilmente a nuevos conjuntos de datos.

Además, la mayoría de estos enfoques trabajan directamente sobre la imagen como una matriz de píxeles, utilizando redes neuronales convolucionales (CNN). Aunque estos modelos han demostrado buenos resultados, no representan de forma explícita las relaciones entre distintas regiones del cerebro, tratándolo únicamente como una imagen bidimensional o tridimensional.

El cerebro puede entenderse como un sistema formado por regiones conectadas entre sí. Por ello, representar estas relaciones mediante grafos puede aportar una forma diferente de analizar la información contenida en las resonancias magnéticas. Sin embargo, actualmente no existen herramientas consolidadas que permitan transformar de manera directa imágenes de RM en grafos listos para ser utilizados en modelos de aprendizaje profundo basados en grafos (Figura 1).

Comentado [AN1]: Tampoco puedes hablar de grafos sin haberlo comentado en la Introducción




Figura 1. Comparativa entre el análisis de RM tradicional (CNN) y el propuesto mediante grafos (GNN). Fuente: Gemini [2]

¹se ha hecho uso puntual de herramientas de IA generativa [40] para hacer una segunda validación de algunos de los estudios previamente seleccionados, y para mejorar la claridad de la redacción en algunos fragmentos del texto.

2.1. EEGGRAPH COMO PUNTO DE PARTIDA

En esta línea, una herramienta relevante es EEGraph [3] una librería desarrollada en Python que permite transformar señales de EEG en grafos con el objetivo de estudiar la conectividad cerebral. Esta herramienta facilita la representación de la actividad neuronal como una red de nodos y conexiones, lo que permite analizar las relaciones entre distintas regiones del cerebro desde una perspectiva estructurada.

Aunque EEGraph está orientada al procesamiento de señales EEG, su enfoque basado en grafos resulta interesante para explorar si una idea similar puede aplicarse a otros tipos de pruebas médicas, como las RMs. En este trabajo se toma como punto de partida esta herramienta, con el objetivo de adaptarla para que permita modelar imágenes de RM como grafos.

2.2. APLICACIÓN DE INTELIGENCIA ARTIFICIAL A RESONANCIAS MAGNÉTICAS

En cuanto al uso de resonancias magnéticas junto con técnicas de inteligencia artificial en el ámbito neurológico, se pueden encontrar distintos estudios que abordan tanto el análisis clínico como la automatización de tareas relacionadas con el diagnóstico. Una muestra de ello es el trabajo de A. Lorenzo Martín [4], donde se estudia la migraña usando lo que se conoce como resonancia de difusión, y se propone un apoyo basado en IA para generar nuevos datos y facilitar el análisis por regiones. Este tipo de trabajos muestra cómo las técnicas de IA pueden ayudar a extraer y organizar la información que contienen las RMs, lo que resulta relevante en el contexto de este PFG, donde también se busca preparar estos datos para su análisis mediante modelos de aprendizaje automático.

Otro trabajo interesante es el de Tsuyoshi Tajima et al. [5], en el cual se plantea un sistema de Deep Learning para identificar automáticamente secuencias de RM craneal, un paso útil para normalizar y ordenar estudios antes de otro análisis. Este tipo de automatización resulta relevante, ya que en muchos casos los estudios de resonancia contienen múltiples secuencias y formatos distintos, lo que dificulta su uso directo en modelos de IA y puede afectar al proceso de entrenamiento. Contar con mecanismos que permitan organizar y preparar estos datos facilita el proceso de preprocesamiento antes de aplicar técnicas de aprendizaje automático.

En otra línea clínica, en el estudio de Frankie K. F. Mo et al. [6] se adapta una CNN 3D para discriminar carcinoma nasofaríngeo en estadios iniciales frente a hiperplasia benigna a partir de RM, mostrando el potencial de estos modelos en la detección automática de patologías. Este tipo de trabajos demuestra cómo los modelos de Deep Learning pueden aplicarse directamente sobre datos de RM para tareas de clasificación médica, lo que refuerza el interés en desarrollar nuevas representaciones de estas imágenes que puedan ser utilizadas por modelos de aprendizaje automático.

Comentado [AN2]: Estás mezclando formas de citar

Por último, como avance, cabe destacar la investigación de Shenbagarajan Anantharajan [7], cuyo objetivo es la detección de diferentes tipos de tumores cerebrales, aplicando técnicas tanto de Machine Learning como de Deep Learning a partir de RMs. Este tipo de trabajos muestra cómo las técnicas de aprendizaje automático se están utilizando cada vez más para analizar información obtenida mediante RM y apoyar tareas de diagnóstico automático.

2.3. PREPROCESAMIENTO Y REPRESENTACIONES INTERMEDIAS DE RESONANCIAS MAGNÉTICAS

En una línea más centrada en transformar y preparar la información de la RM para hacer uso de ella mediante IA, hay trabajos que proponen representaciones intermedias o pipelines de entrenamiento/preprocesamiento. Así, metodologías como la propuesta en el trabajo de Xiaohong Liang MD [8], basa su preprocesamiento en transformar secuencias de RM en vectores de características radiómicas para, aplicando técnicas de Deep Learning, entrenar un modelo predictivo de tumores cerebrales. Este tipo de enfoque nos permite observar cómo, antes de aplicar los modelos de IA, es habitual transformar las RMs en representaciones intermedias más manejables para el modelo.

Desde una perspectiva más geométrica, en el estudio de Rodrigo Santa Cruz [9] se propone la arquitectura DeepCSR, basada en Deep Learning para la reconstrucción de la corteza cerebral a partir de RM, acelerando los flujos tradicionales de análisis de la corteza. Este tipo de trabajos muestra cómo es posible extraer representaciones estructurales del cerebro a partir de imágenes de RM utilizando modelos de Deep Learning, lo que resulta relevante para enfoques que buscan trabajar con representaciones más estructuradas de la información cerebral.

En esta misma línea de transformación espacial, el modelo Point2Mesh-Net de Vicente Grau [10] convierte cortes 2D de RMs en mallas 3D, permitiendo obtener una representación geométrica más estructurada de la información cardíaca, lo cual facilita el análisis al no tener que lidiar con los datos en bruto. Esto resulta relevante en el contexto de este PFG, donde también se busca transformar las resonancias en una estructura más adecuada para su análisis mediante modelos de aprendizaje automático.

Asimismo, enfoques como el que vemos en este otro trabajo de Shu-Hang Ng et al. [11], automatizan la extracción de datos mediante un preprocesamiento de las RMs aislando tumores y extrayendo datos sobre ellos. Este tipo de metodologías busca reducir la carga asociada al delineado manual realizado por especialistas. En este sentido, estos trabajos muestran cómo la automatización del procesamiento de las RMs puede facilitar su posterior análisis mediante modelos de aprendizaje automático.

A modo de síntesis de todas estas técnicas, en este estudio de Alfonso Bueno-Orovio [12] se revisan exhaustivamente los métodos para reconstruir modelos 3D a partir de cortes 2D de RM haciendo uso de técnicas de Deep Learning. Este tipo de reconstrucción puede ser útil como paso previo, ya que permite trabajar con una representación tridimensional más completa del cerebro, lo que puede facilitar posteriormente la extracción de regiones, la

definición de nodos y, en definitiva, la construcción del grafo que se utilizará como entrada para los modelos de aprendizaje profundo.

2.4. REPRESENTACIÓN MEDIANTE GRAFOS Y MODELOS BASADOS EN GNN

Finalmente, el enfoque más cercano al objetivo de este trabajo es aquel que representa pruebas cerebrales como grafos y los utiliza para analizar la conectividad y, en muchos de los casos, apoyar tareas de predicción mediante Deep Learning y Machine Learning. Un excelente punto de partida para entender este enfoque es el trabajo de David Ahméd-Aristizabal [13], donde se presenta una revisión del uso de grafos y de GNNs en medicina, con el objetivo de demostrar que estas últimas superan a los métodos tradicionales al ser capaces de entender las relaciones entre distintas partes del cerebro. Incluye ejemplos como EEG o fMRI para tareas de análisis y predicción, mostrando por qué estas representaciones son útiles cuando hay relaciones entre regiones del cerebro.

Concretamente en el ámbito de las señales eléctricas, un trabajo interesante es el de Gürçan Yavuz [14], donde hay un capítulo en el que hablan de “Graph-Based Deep Learning Approaches for EEG Interpretation and Brain Connectivity Modeling”. Profundizan en cómo transformar registros de EEGs a grafos, tomando los electrodos como nodos y luego usando la conectividad funcional para las aristas. Esa matriz resultante se utiliza como entrada de una GNN o una GCN para clasificar e interpretar estados mentales. Este enfoque resulta especialmente relevante para este PFG, ya que muestra un ejemplo claro de cómo representar datos neurofisiológicos mediante grafos y cómo integrarlos posteriormente en modelos de aprendizaje profundo basados en grafos. Aunque el tipo de dato es diferente (EEG frente a MRI), la lógica de construcción y uso del grafo es similar a la que se plantea en este trabajo.

Llevando esta misma filosofía al terreno de la neuroimagen, un estudio a destacar es el de Kini Chen [15], en el cual aplican redes GCN a fMRIs, con el objetivo de predecir si el paciente estaba en reposo o realizando una tarea cognitiva. En este caso, no se utilizan únicamente datos a nivel de grafo completo, sino también a nivel de nodo, permitiendo capturar con mayor detalle las relaciones entre distintas regiones del cerebro, y una mayor precisión del modelo. Esto permite ver y analizar cómo se comunican las distintas zonas del cerebro.

Finalmente, como ejemplo integral de aplicación práctica, en este trabajo de L. PASA [16], se detalla el proceso paso a paso para transformar fMRIs en grafos dinámicos, que posteriormente se utilizan como entrada de distintos modelos con el objetivo de clasificar a los pacientes y detectar la presencia de trastornos del espectro autista, utilizando el dataset ABIDE.

Comentado [AN3]: Acrónimo de?

2.5. LIMITACIONES DE LOS TRABAJOS EXISTENTES Y APORTACIÓN DEL PFG

Aunque los trabajos revisados demuestran que es posible utilizar resonancias y grafos en tareas de análisis y predicción, la mayoría se centran en un caso muy concreto: un tipo de prueba, un método de construcción del grafo y un modelo aplicado a un dataset específico. En muchos casos, además, el proceso completo queda ligado al propio experimento descrito en el artículo, sin ofrecer herramientas reutilizables que permitan aplicar el mismo enfoque fácilmente a otros datos o contextos. Este trabajo busca precisamente cubrir ese hueco, proponiendo un enfoque que permita transformar resonancias magnéticas en grafos de forma más general y preparar dichos grafos para su uso posterior en modelos de aprendizaje automático.

3. OBJETIVOS

3.1. OBJETIVO GENERAL

El objetivo principal de este Proyecto Fin de Grado es **desarrollar una librería capaz de modelar pruebas médicas neuronales**, como pueden ser RMs, de imagen a grafo, transformándolas, por tanto, en representaciones estructuradas que reflejen la conectividad entre regiones, con el fin de utilizarlas posteriormente en modelos de diagnóstico basados en Deep Learning y **facilitando así su análisis para el estudio de la conectividad cerebral y el apoyo a tareas de diagnóstico automático**.

3.2. LISTA DE OBJETIVOS ESPECÍFICOS

Para alcanzar el objetivo principal, se plantean los siguientes objetivos específicos, que corresponden a las distintas fases del trabajo:

1. **Realizar un estudio de datasets abiertos de neuroimagen cerebral** que puedan utilizarse para desarrollar y evaluar un caso de uso basado en la clasificación entre sujetos con enfermedad de Parkinson y controles sanos.
2. **Diseñar e implementar un método de transformación de imágenes de fMRI en grafos**, de manera que se pueda estudiar la conectividad cerebral a partir de dichas representaciones.
3. **Desarrollar un flujo de preprocesamiento de fMRI**, utilizando al menos uno de los datasets seleccionados previamente, que permita preparar los datos de entrada de forma homogénea antes de su transformación a grafos.
4. **Entrenar uno o varios modelos de Deep Learning** para resolver un caso de uso médico concreto a partir de los datos procesados.
5. **Evaluar el rendimiento de los modelos** mediante métricas matemáticas adecuadas para el problema planteado.
6. **Integrar los módulos desarrollados en una librería funcional y reutilizable**, que permita realizar el proceso completo desde la entrada de la prueba médica hasta la generación y visualización tanto del grafo como de la matriz de conectividad.

3.3. MÉTODOS DE VALIDACIÓN

Para validar el cumplimiento de los objetivos específicos descritos anteriormente, se proponen los siguientes métodos de validación.

1. **Resultado esperado:** Se considerará cumplido si se presenta una revisión de los datasets utilizados, indicando su procedencia, modalidad de imagen, composición general, clases disponibles, utilidad metodológica y criterio de incorporación al caso de uso. Además, deberá justificarse qué datasets se utilizan para entrenamiento, evaluación y test, y qué limitaciones presentan por tamaño muestral, heterogeneidad o distribución de clases.
2. **Resultado esperado:** Se considerará cumplido si la librería permite cargar una imagen fMRI, extraer señales regionales mediante un atlas cerebral, calcular una matriz de conectividad funcional y generar una estructura de grafo correctamente definida. Para poder dar por válido este objetivo, se describirá el flujo que sigue un archivo fMRI para ser transformado en grafo. La validación se realizará comprobando la generación de matrices de conectividad, grafos serializados y visualizaciones en formato HTML y PNG para ejemplos reales.
3. **Resultado esperado:** Se considerará cumplido si los fMRIs seleccionados se procesan mediante un flujo reproducible que genere imágenes preprocesadas, informes de control de calidad y salidas compatibles con la transformación posterior a grafo.
4. **Resultado esperado:** Se considerará cumplido si se entrena al menos un modelo de Deep Learning basado en grafos capaz de recibir como entrada las representaciones generadas por la librería. La validación incluirá la definición de la arquitectura, los hiperparámetros utilizados, el procedimiento de entrenamiento, el uso de early stopping y la separación entre entrenamiento, evaluación y test.
5. **Resultado esperado:** Se considerará cumplido si se presenta un informe de resultados con métricas de clasificación, incluyendo loss, accuracy, recall, F1-score, AUC y matriz de confusión. Además, se incorporará una validación cruzada para estimar la estabilidad del modelo.
6. **Resultado esperado:** Se considerará cumplido si el repositorio final contiene una estructura organizada, módulos reutilizables y ejemplos de uso. Se deberá hacer uso de la estructura ya existente en la librería, haciendo por tanto una ampliación de la librería existente y no una librería nueva. Haciendo por tanto que la interacción del usuario con la herramienta no varíe respecto a la actual.

4. METODOLOGÍA Y PLAN DE TRABAJO

4.1. MATERIALES Y RECURSOS

Para el desarrollo de este PFG se han utilizado distintos recursos técnicos y humanos, que han permitido abordar tanto la ampliación de la librería como la posterior fase de creación de una red neuronal sobre grafos.

4.1.1. Recursos de Software

En cuanto a los recursos de software, el desarrollo principal del proyecto se ha realizado en la aplicación de Microsoft **Visual Studio Code [17]**, utilizado como entorno de programación durante la implementación, prueba y revisión del código.

Para la comunicación, alineamiento y resolución de dudas con el tutor, se ha hecho uso de la aplicación **Slack [18]**, la cual nos ha permitido mantener un contacto y un seguimiento continuo del proyecto y tomar decisiones técnicas puntuales a lo largo de todo el proyecto.

Para la elaboración del cronograma y la planificación temporal del trabajo, se ha utilizado la aplicación de escritorio utilizada a lo largo de la carrera: **GanttProject [19]**.

A nivel de programación, el proyecto se ha desarrollado en lenguaje **Python [20]**, junto con distintas librerías orientadas al tratamiento de datos biomédicos, análisis numérico, construcción de grafos y visualización. Para la primera parte del PFG, en la cual se ha ampliado una librería de Python, destacan las utilizadas para manipulación de matrices y estructuras numéricas, para el tratamiento de archivos NIfTI, para la generación de grafos y para la visualización. Para la segunda parte del proyecto, en la cual se ha creado una red neuronal sobre grafos, destacan más las propias de los algoritmos de Deep Learning y aprendizaje sobre grafos como son **PyTorch [21]** y **PyTorch Geometric [22]**, junto con otras herramientas para entrenamiento, validación y tratamiento de los datos.

Para realizar las citas en el documento de la memoria, se ha hecho uso de **Mendeley Cite [23]**, una extensión de Word que permite añadir referencias, citarlas en el documento y referenciarlas en la bibliografía de manera más sencilla.

4.1.2. Recursos de Hardware

Respecto a los recursos de hardware, el proyecto se ha desarrollado en mi **ordenador personal** como principal herramienta de trabajo, y en el cual están instalados los recursos de software mencionados en el punto anterior.

4.1.3. Datos y Recursos Externos

Para la construcción del dataset empleado en la clasificación mediante grafos con un modelo GNN se combinaron varios repositorios de resonancia magnética funcional en reposo. En todos los casos se trabajó con archivos de fMRI en formato NIFTI, adecuados para extraer series temporales por regiones cerebrales y, a partir de ellas, construir matrices de conectividad funcional y grafos. Una parte de los datos procede de **OpenNeuro [24]**, una plataforma abierta para compartir datos de neuroimagen, orientada a datasets estructurados, y otra parte procede del conjunto **Neurocon [25]**, utilizado como fuente adicional de sujetos con y sin enfermedad de Parkinson.

OpenNeuro ha resultado especialmente útil porque reúne datasets de neuroimagen organizados siguiendo el estándar BIDS [26], lo que facilita trabajar de forma homogénea con imágenes de resonancia metadatos y archivos auxiliares. En este tipo de repositorios, los datos suelen distribuirse en formatos habituales de neuroimagen, como **imágenes NIFTI y archivos complementarios JSON y TSV**, lo que simplifica su integración dentro del flujo de procesamiento de la librería. En este trabajo, estos recursos se han utilizado para disponer de casos reales de fMRI sobre los que probar la extracción de ROIs, la construcción de grafos y su posterior uso en modelos basados en grafos.

Respecto a Neurocon, este dataset contiene datos de fMRI en reposo de pacientes con enfermedad de Parkinson y sanos de edad similar. Este recurso ha sido especialmente útil porque responde bien al caso de uso planteado en el proyecto: trabajar con fMRIs reales en un contexto neurológico y con una diferenciación clara entre grupos, lo que permite comprobar si la representación en grafos conserva información relevante para análisis posteriores.

Por otro lado, en la versión final de la librería se han dejado soportados los atlas **AAL, Schaefer 100, Schaefer 200 y Schaefer 400**. Un atlas cerebral puede entenderse como una parcelación del cerebro en regiones de interés (ROIs) definidas previamente. En este proyecto su uso es necesario porque permite dividir el cerebro en zonas concretas, extraer la señal temporal asociada a cada una de ellas y utilizar esas regiones como nodos del grafo. Es decir, el atlas actúa como una referencia común que permite pasar de la imagen de fMRI a una representación estructurada de la conectividad cerebral. Los archivos de estos atlas se incorporaron a la librería a partir de un repositorio de GitHub [27] con el objetivo de que pudieran utilizarse directamente dentro del flujo de trabajo sin depender de descargas externas adicionales en cada ejecución. De este modo, la herramienta queda más cerrada, reproducible y fácil de reutilizar en futuros experimentos.

4.1.4. Recursos Humanos

En cuanto a los recursos humanos, el proyecto ha contado en primer lugar con la supervisión del tutor: **Alberto Nogales**, que ha orientado el enfoque general del trabajo y ha ayudado a revisar y a tomar distintas decisiones relacionadas con la planificación, diseño, arquitectura y validación de la solución desarrollada.

Del mismo modo, durante el desarrollo del proyecto se ha recibido asesoramiento puntual por parte de dos compañeros del entorno profesional en el que he trabajado mientras realizaba el PFG. Su ayuda ha sido especialmente útil para resolver dudas técnicas complejas y para orientar determinadas decisiones de implementación conforme a buenas prácticas de programación. Ambos cuentan con experiencia consolidada en inteligencia artificial y desarrollo de software, concretamente con 7 y 9 años de trayectoria profesional, por lo que sus aportaciones han tenido un valor significativo para el desarrollo del trabajo.

La validación de la librería no se ha apoyado únicamente en las pruebas realizadas durante el desarrollo, sino también en pruebas adicionales llevadas a cabo por **Alberto Nogales e Iván Barcia**, que han servido para reforzar la revisión del funcionamiento global antes de dar por cerrada esta parte del proyecto.

Por último, también se ha contado con el apoyo de una profesional del ámbito sanitario con 6 años de experiencia en el área de la neurofisiología, cuya colaboración ha sido útil para elaborar una introducción contextual que permita a cualquier lector de este documento comprender de forma general qué son y para qué sirven las técnicas neurológicas mencionadas a lo largo del trabajo.

4.1.5. Metodología

En cuanto a la metodología, se ha seguido un enfoque iterativo y por fases, adecuado para un proyecto que combina una parte de desarrollo software con una parte experimental basada en modelos de aprendizaje sobre grafos. El proyecto se ha organizado por etapas sucesivas, siguiendo una estructura como la siguiente: una primera fase de estudio del problema e investigación, una segunda fase de análisis y ampliación de la librería junto con una validación, una tercera fase dedicada a la red neuronal, y una última fase de análisis de resultados, revisión final, y finalización de la documentación.

Se decidió seguir esta metodología porque permitía avanzar de forma ordenada, manteniendo una relación clara entre las distintas partes del PFG, ya que debíamos hacer la ampliación de la librería previo a la realización de la GNN.

4.2. MÉTODOS

4.2.1. Enfoque metodológico del trabajo

La metodología seguida en este trabajo se estructuró en dos bloques principales y complementarios. El primero consistió en la ampliación de la librería EEGraph para permitir el procesamiento de estudios de fMRI en reposo y su transformación en grafos cerebrales. El segundo bloque se centró en el desarrollo de una prueba de concepto basada en una GNN, utilizando como entrada los grafos obtenidos a partir de dichas resonancias. Este planteamiento permitió separar claramente la construcción del pipeline técnico de la validación experimental del caso de uso médico planteado.

El objetivo metodológico no fue únicamente entrenar un modelo de clasificación, sino construir un flujo de trabajo reproducible que permitiese partir de una prueba de neuroimagen en formato **NIFTI**, transformarla en una representación basada en conectividad cerebral y utilizar dicha representación como entrada de un modelo de Deep Learning. Para ello, el trabajo se organizó en varias etapas: diseño del pipeline de transformación de fMRI a grafos, selección de datasets, construcción del conjunto experimental, diseño de la prueba de concepto con GNN y criterios de evaluación.

Además, desde el punto de vista de ingeniería, se optó por no desarrollar una librería nueva desde cero, sino por ampliar EEGraph manteniendo una interfaz pública común para EEG y fMRI. Esta decisión condicionó toda la metodología técnica, ya que obligó a integrar la nueva modalidad sin romper el flujo original de uso de la herramienta.

Para la prueba de concepto, se decidió aplicar una serie de preprocesamientos a los datasets seleccionados, previos a la transformación a grafos mediante la librería desarrollada, con la intención de estandarizar al máximo los datos y conseguir unos buenos resultados en la GNN. Estos preprocesamientos se detallan en el [Anexo D: Preprocesamientos Prueba de Concepto](#).

4.2.2. Diseño del método de transformación de fMRI a grafos

La transformación de las resonancias fMRI en grafos cerebrales se diseñó como una ampliación integrada dentro de EEGraph. Desde el punto de vista del usuario, la interacción se mantuvo lo más simple y similar posible a como se hacía previo a añadir la posibilidad de transformar fMRIs: la entrada sigue realizándose a través de la clase Graph, indicando la modalidad correspondiente ("eeg" o "fmri"), mientras que el flujo interno cambia automáticamente en función de si la entrada es una u otra.

En el caso de la modalidad fMRI, el usuario carga el NIFTI y, posteriormente, solicita el modelado especificando la medida de conectividad, el umbral y la configuración del atlas. Esta decisión permitió conservar una única puerta de entrada pública, evitando fragmentar la experiencia de uso en dos herramientas diferentes.

Internamente, la cadena de procesamiento para fMRI quedó organizada en varias fases consecutivas. En primer lugar, se realiza la carga del archivo **NIFTI 4D** y la validación de que la entrada tenga la estructura esperada para una resonancia funcional. A continuación, se aplica un preprocesamiento sobre la señal y una fase de eliminación de ruido (denoising). Concretamente se aplica una limpieza de valores no finitos (NaN, +inf y -inf), una normalización global sobre todo el volumen 4D, dejando media 0 y desviación típica 1, una conversión del volumen 4D a una matriz voxel $\times$ tiempo (sirve como preparación de la señal para las fases posteriores de denoising, extracción ROI y conectividad), y, si existe un archivo auxiliar que contenga una matriz de confounds, aplica una regresión de confounds². Estos preprocesamientos son propios de la librería, a diferencia de los mencionados en el punto anterior.

² La regresión de confounds es una técnica que elimina de la señal la parte de variabilidad explicada por factores de ruido conocidos, y se utiliza para reducir la influencia de artefactos como movimiento o señales no neuronales antes del análisis. [41]

Posteriormente, se lleva a cabo la transformación anatómica mediante atlas, extrayendo una representación **ROI × tiempo**, y a partir de ella se calcula una matriz de conectividad **ROI × ROI**. Finalmente, con dicha matriz se construye el grafo cerebral final, añadiendo etiquetas anatómicas, posiciones espaciales y metadatos útiles para su visualización.

Desde el punto de vista formal, la representación generada puede entenderse como un grafo

$$G = (V, E)$$

Ecuación 1: Representación generada como grafo. Fuente: Elaboración propia

donde V es el conjunto de nodos y E el conjunto de aristas. En este trabajo, cada nodo representa una ROI definida por un atlas, mientras que cada arista representa la relación de conectividad funcional entre dos regiones.

Para acotar el alcance del desarrollo y asegurar la estabilidad del pipeline, se limitaron los **atlas soportados** a AAL, Schaefer 100, Schaefer 200 y Schaefer 400. Esta restricción fue intencionada, ya que permitía documentar y validar un conjunto reducido de atlas realmente comprobados, en lugar de dejar abierto el soporte a configuraciones no verificadas. Además, cuando el atlas y el fMRI no coincidían exactamente en espacio o resolución, se habilitó la posibilidad de realizar un rescaldo (resampling), de forma que el atlas pudiera adaptarse al espacio de la imagen funcional sin obligar al usuario a realizar una preparación manual previa.

Una vez resuelto el atlas, se extraen las series temporales medias de cada ROI, obteniéndose la matriz **ROI × tiempo**. Esta matriz actúa como puente entre la imagen y el análisis de conectividad. En el estado final de la implementación, la medida de conectividad principal utilizada en la prueba de concepto fue la **correlación de Pearson**, que permite cuantificar el grado de asociación lineal entre las series temporales de dos regiones. De forma teórica, esta medida puede expresarse como:

$$r_{ij} = \frac{\sum_t (x_i(t) - \bar{x}_i)(x_j(t) - \bar{x}_j)}{\sqrt{\sum_t (x_i(t) - \bar{x}_i)^2} * \sqrt{\sum_t (x_j(t) - \bar{x}_j)^2}}$$

Ecuación 2: Correlación de Pearson. Fuente: Elaboración propia

donde $x_i(t)$ y $x_j(t)$ son las series temporales de dos ROIs. Además de esta medida, la librería quedó preparada para trabajar también con correlación cruzada:

$$CC_{ij} = \frac{1}{d} \sum_{m=0}^{d-1} R_{ij}(m)$$

Ecuación 3: Correlación Cruzada. Fuente: Elaboración propia

Donde $d = \max(1, \text{round}(0.1 * T))$ siendo T es el número de puntos temporales de la serie.

Y también se puede trabajar con la correlación cruzada corregida:

$$CCC_{ij} = \frac{1}{d} \sum_{m=1}^d (R_{ij}(m) - R_{ij}(-m))$$

Ecuación 4: Correlación Cruzada Corregida. Fuente: Elaboración propia

donde, de nuevo, $d = \max(1, \text{round}(0.1 \cdot T))$ siendo T es el número de puntos temporales de la serie.

En la fase final del modelado, la **matriz de conectividad** se convierte en la base del grafo. Cuando el usuario define un umbral, las conexiones por debajo de dicho valor se eliminan, conservándose únicamente las relaciones más fuertes. En términos conceptuales, esto puede expresarse como:

$$A_{ij} = \begin{cases} r_{ij} & \text{si } r_{ij} \geq \eta \\ 0 & \text{en caso contrario} \end{cases}$$

Ecuación 5: Matriz de Conectividad. Fuente: Elaboración propia

en caso contrario, donde η es el umbral aplicado. En la prueba de concepto de este trabajo se fijó $\eta = 0.5$, aunque también se probó con 0.3 y 0.7, para tener datos que son realmente representativos y no sobrecargar a futuro la prueba de concepto con datos innecesarios, de manera que solo se conservaron conexiones suficientemente intensas para construir una representación más limpia y comparable entre sujetos

Otro aspecto metodológico importante estuvo relacionado con la **visualización** y la coherencia anatómica de los grafos. En versiones intermedias, los centroides de las regiones se manejaban en coordenadas de voxel, lo que podía provocar que las representaciones fueran poco intuitivas. Para mejorar esta parte, la implementación final pasó a trabajar con centroides en “coordenadas mundo”. Además, el grafo conserva la posición 3D de cada ROI y una proyección 2D utilizada en la visualización, empleándose finalmente una proyección axial (aunque también se puede establecer como coronal) en la que se muestra la profundidad mediante escala de colores para no perder completamente la tercera dimensión.

Se muestra a continuación un ejemplo de ambas representaciones:




Figura 2. Representación con perspectiva axial y coronal de un fMRI transformado a grafo usando la librería desarrollada. Fuente: Elaboración propia

4.2.3. Selección y caracterización de los datasets

Como aclaración inicial, cabe mencionar que se denomina “patient” a un sujeto que padece la enfermedad, en este caso parkinson, y “control” a un sujeto sano.

Para la construcción del conjunto de datos empleado en la prueba de concepto se combinaron varios repositorios abiertos de fMRI en reposo, todos ellos adecuados para extraer series temporales por regiones cerebrales y, a partir de ellas, construir matrices de conectividad funcional y grafos. Los datos se obtuvieron tanto de OpenNeuro como del conjunto Neurocon, utilizándose muestras de sujetos con enfermedad de Parkinson y de sujetos sanos. En todos los casos se trabajó con archivos en formato .nii.gz, adecuados para representar volúmenes 4D de fMRI.

En [Anexo A: Detalle de Datasets Utilizados](#) se detallan los datasets seleccionados.

La selección de datasets se realizó buscando un equilibrio entre disponibilidad abierta, adecuación al problema clínico, compatibilidad con la representación en grafos y presencia de adquisiciones de fMRI en reposo. No se persiguió construir un dataset clínicamente perfecto, sino un conjunto suficientemente amplio y reutilizable para validar la viabilidad del pipeline propuesto y de la prueba de concepto posterior.

4.2.4. Construcción del dataset de grafos para la prueba de concepto

Una vez seleccionados los datasets, todos los archivos de fMRI en formato .nii.gz se organizaron manualmente en dos grandes grupos, patient y control, según la clase clínica que debían representar en la tarea de clasificación binaria. Esta organización inicial no servía todavía como dataset de entrenamiento definitivo, era más bien una fase previa de preparación orientada a facilitar la transformación de todas las muestras a una representación en grafos.

A partir de esa organización, cada archivo fMRI fue procesado individualmente mediante el pipeline implementado en la librería. De cara a poder obtener un dataset homogéneo, en todas las transformaciones se trabajó con el **atlas AAL**, se calculó la conectividad mediante la **correlación de Pearson**, se aplicó un **umbral de 0.5** y se utilizó un **window_size = 1.0**, lo que implica que la conectividad se calculó de forma estática a partir de toda la serie temporal disponible y no mediante conectividad dinámica por ventanas. Como resultado, cada sujeto dio lugar a una única matriz de conectividad y a un único grafo cerebral.

Además de la generación del grafo, para cada sujeto se almacenaron varios archivos auxiliares que permitían conservar tanto la estructura obtenida como su inspección posterior. En concreto, se guardó la **matriz de conectividad** en formato .npz, el propio **grafo** en formato .pkl y **visualizaciones del resultado** en HTML y PNG dentro de una carpeta propia para cada sujeto. Esto permitió tener un registro completo de cada fMRI transformado, permitiendo no solo trabajar con la GNN gracias a las matrices de conectividad, si no poder comprobar manualmente que las transformaciones, y por tanto el funcionamiento de la librería, han sido correctas para cada uno de los sujetos gracias a las visualizaciones.

Tras esta fase de generación se obtuvieron inicialmente **195 muestras**, de las cuales **112** correspondían a la clase “patient” y **83** a la clase “control”. Sin embargo, durante la revisión de las matrices de conectividad generadas se observó que no todas presentaban el tamaño esperado de **116 × 116** asociado al atlas AAL. En algunos casos aparecieron matrices de dimensiones inferiores porque no fue posible extraer una serie temporal válida para todas las regiones del atlas, algo que por suerte se pudo mitigar en gran medida gracias al script de preprocesamiento desarrollado. Esto puede deberse a problemas de solapamiento entre el atlas y la imagen funcional tras el resamplado, a diferencias en el campo de visión, a la aplicación de máscaras cerebrales o a regiones sin voxels válidos. Dado que esta situación rompía la homogeneidad del dataset, se decidió conservar únicamente aquellas matrices que mantenían las **116 ROIs** esperadas.

Después de aplicar este filtrado, el conjunto quedó reducido a **178 muestras** válidas, de las cuales **105** pertenecían a la clase patient y **73** a la clase control. Sobre este subconjunto homogéneo se realizó un balance para asegurar que la red no aprendiese diferencias entre datasets, y se ajustaron todos los datasets a una distribución de **13** control y **25** patient. Debido a que se ha trabajado con distintos datasets, para asegurarnos de que la GNN realmente aprende, se dejó un dataset exclusivamente para test (en este caso fue neurocon), aplicando la técnica de **leave-one-out**, y para el conjunto de entrenamiento, de validación, se aplicó **Pareto** con los datasets restantes. Esta división consiste en 2 pasos: primero se separa un 20% para test, y del 80% restante se separa un 20% para validación y un 80% para entrenamiento, pero en este trabajo únicamente se hizo una división 80% entrenamiento y 20% evaluación.

Antes de convertir estas matrices en objetos compatibles con PyTorch Geometric, se aplicaron varias **acciones de limpieza y tratamiento** de los datos. Concretamente, se eliminaron valores **NaN e infinitos**, que pueden aparecer durante el cálculo de conectividad cuando alguna región presenta una señal temporal constante, nula, con varianza prácticamente cero o con muy pocos voxels válidos, se forzó la **simetría de la matriz**, se **anuló la diagonal** para evitar autoconexiones y se descartaron las **correlaciones negativas** estableciendo la variable creada “USAR_ABSOLUTO” en False. Posteriormente, las características de cada nodo se construyeron utilizando la fila completa de conectividad correspondiente a su ROI, de modo que cada nodo quedó representado por un vector de **116 características**. Finalmente, para definir las aristas del grafo final utilizado por la red, se conservaron las **20 conexiones positivas más relevantes** por nodo, aunque se hicieron pruebas mediante grid search para encontrar la mejor combinación.

Este procedimiento permitió construir un dataset homogéneo de grafos cerebrales para una clasificación binaria entre sujetos con Parkinson y sujetos sanos. Desde el punto de vista metodológico, esta decisión fue especialmente importante, ya que garantizó que el modelo recibiera entradas con la misma dimensionalidad.

4.2.5. Diseño y desarrollo de la prueba de concepto con GNN

La prueba de concepto se planteó con el objetivo de comprobar si la representación en grafos obtenida a partir de las resonancias funcionales contenía información suficiente para

discriminar entre sujetos con Parkinson y sujetos sanos. Para ello, se optó por utilizar una **GNN**, ya que este tipo de modelos está específicamente diseñado para trabajar con datos donde la información no se organiza como una imagen o una tabla, sino como nodos conectados mediante aristas.

La entrada del modelo fue, por tanto, un grafo por sujeto, y cada grafo estaba compuesto por un conjunto de nodos que representaban las 116 regiones del atlas AAL y por un conjunto de aristas definidas a partir de la conectividad funcional positiva más relevante.

Desde el punto de vista experimental, la prueba de concepto se diseñó como un problema de clasificación binaria supervisada, donde la etiqueta objetivo era distinguir entre la clase “patient” y la clase “control”. La división del entrenamiento, la validación y el test, se realizaron sobre un subconjunto preprocesado y homogeneizado.

La expectativa metodológica asociada a esta prueba de concepto no fue demostrar una herramienta clínica cerrada, sino verificar que el pipeline completo era funcional y que la representación basada en grafos generada por la librería podía alimentar un modelo de aprendizaje profundo con capacidad de generalización razonable. En otras palabras, se buscó comprobar si el paso desde la imagen fMRI al grafo cerebral no solo era técnicamente viable, sino también útil desde el punto de vista predictivo dentro de un caso de uso médico concreto.

4.2.6. Criterios de evaluación

La evaluación del trabajo se planteó en dos niveles, el primero correspondió al rendimiento del modelo y el segundo al análisis de los grafos generados.

En cuanto al primero, la validez de la prueba de concepto se valoró mediante métricas habituales en problemas de clasificación binaria como son **accuracy**, **precision**, **recall**, **F1-score**, **AUC** y la **matriz de confusión**. Estas medidas permiten cuantificar no solo el porcentaje de aciertos del modelo, sino también la capacidad que tiene para clasificar correctamente a los sujetos y la capacidad de generalización.

En el segundo nivel, se comprobó que todos los datos utilizados tenían sentido estructural en la visualización, los ROIs estaban dispuestos de forma lógica en el espacio, no solo en el eje x e y, si no también en cuanto a la profundidad representada por la escala de colores. Se validó también la capacidad de la herramienta de poder transformar un grafo que necesitase resampling, y la capacidad de la herramienta de poder indicar un error preciso para cualquier error relacionado con las variables o con los archivos introducidos por el usuario.

De este modo, la metodología del trabajo no se limitó a entrenar un modelo y medir su rendimiento, sino que combinó desarrollo de software, construcción de representación, validación experimental y análisis estructural. Esta combinación resultó coherente con el objetivo general del proyecto, que no era únicamente clasificar sujetos, sino demostrar la viabilidad de un flujo completo capaz de transformar fMRIs en grafos y aprovechar esa representación en una prueba de concepto basada en inteligencia artificial.

4.3. PLAN DE TRABAJO

Para la planificación del proyecto se definió una estructura jerárquica compuesta por paquetes de trabajo (PT), actividades (ACT) y tareas (TR), lo que permitió organizar de manera detallada las distintas fases del PFG. Aunque se trata de un proyecto desarrollado de forma individual, se han definido distintos perfiles de recurso en función del tipo de trabajo realizado. Asimismo, se ha considerado una validación externa puntual de la librería desarrollada. Los recursos creados son los siguientes:

Recurso	Perfil	Función principal
R1	Investigador y analista metodológico	Estudio de la librería base, investigación sobre fMRI, análisis metodológico y definición del enfoque técnico
R2	Desarrollador de software	Implementación, integración, depuración, pruebas y validación técnica de la librería y la prueba de concepto
R3	Documentación, revisión y reescritura	Redacción de la memoria, revisión de contenidos, reescritura de apartados y preparación de la versión final
R4	Validador externo 1	Validación funcional externa de la librería
R5	Validador externo 2	Validación funcional externa de la librería

Tabla 1: Recursos Creados para el Gantt del Plan de Trabajo. Fuente: Elaboración propia.

Debido a que una explicación detallada de ambos planes de trabajo ocupa una gran cantidad de espacio, se ha creado un [Anexo B: Planes de Trabajo](#) en el cual se incluyen tablas e imágenes del detalle de cada plan.

4.3.1. Plan de Trabajo Inicial

A continuación, la duración del proyecto dividida en paquetes de trabajo. La franja de color rosa entre el 2 de febrero y el 10 de febrero corresponde a un periodo vacacional de los recursos R1, R2 y R3. En el periodo de Navidad los recursos tampoco estuvieron disponibles para continuar con sus tareas. Por lo que se estimó comenzar tras la finalización de las mismas con el paquete 3, habiendo dejado finalizado el paquete 2 previamente.




Figura 3. Plan de Trabajo Inicial completo. Fuente: Elaboración propia

4.3.2. Plan de Trabajo Final

Finalmente, se alargó el paquete de trabajo 1 más de lo previsto, por lo que no se pudo tener la pausa prevista entre paquetes en el periodo de Navidad. La prolongación del primer paquete provocó un comienzo tardío del paquete PT2, por lo que no se pudo finalizar antes

del periodo vacacional de los recursos R1, R2 y R3. La solución que se encontró a este inconveniente fue la paralelización de la última actividad del segundo paquete con el comienzo del tercer paquete, algo que ayudó a mitigar mucho el retraso acumulado y terminó de solventarse con una mayor paralización en los paquetes posteriores.




Figura 4. Plan de Trabajo Final completo. Fuente: Elaboración propia

4.4. CONDICIONANTES Y LIMITACIONES

Durante el desarrollo de este PFG, se encontraron varios condicionantes que influyeron tanto en el diseño de la solución como en el ritmo de implementación, lo cual provocó que los recursos tuvieran que dedicar más horas al día de lo previsto durante algunos días del proyecto.

El primero de los condicionantes fue la carga de trabajo de los recursos procedentes de otras fuentes como trabajo, exámenes y prácticas durante el primer paquete de trabajo, lo cual provocó que tomase más tiempo del previsto la realización del mismo.

Otro condicionante importante ocurrió durante el paquete PT2. La documentación tuvo que ser reescrita más veces de lo previsto, lo cual provocó que se tuviera una predicción de demora que superaba el tiempo establecido para la realización de esta parte. Esto llevó a tener que dedicar más horas a los recursos cada día para poder mitigar al máximo este retraso.

Ya entrados en el tercer paquete, los tiempos generales fueron más o menos los estimados, pero a mitad del periodo de la actividad ACT3.1, se detectó una equivocación del recurso R2 en la codificación, ya que se estaba desarrollando el código de la ampliación de la librería como si fuera una librería aparte. A pesar del error, se detectó pronto y se pudo reestructurar el código relativamente rápido, haciendo uso de las horas que se pensaron como margen por si ocurrían incidentes.

A estos condicionantes se sumó uno especialmente relevante durante PT5, en la fase de desarrollo de la prueba de concepto basada en GNN. La dificultad no residió únicamente en programar y entrenar el modelo, sino en garantizar previamente una cadena de datos homogénea desde el fMRI original hasta el grafo final. En la implementación desarrollada fue necesario trabajar con volúmenes fMRI 4D válidos. Esto supuso una limitación técnica importante, ya que no todas las muestras podían incorporarse directamente al experimento sin una revisión previa, por lo que antes de entrenar el modelo fue necesario comprobar que las entradas fueran realmente válidas, que la dimensionalidad resultante fuera coherente entre muestras y que las matrices de conectividad y los grafos generados mantuvieran una estructura adecuada para su uso posterior.

También, el desarrollo de la GNN puso de manifiesto otra limitación habitual en este tipo de proyectos. Aparecieron varios problemas en cuanto a los resultados obtenidos, ya que no se conseguía obtener una combinación de hiperparámetros que diese buenos resultados de precisión y sin que existiese overfitting. Finalmente se aplicaron una serie de buenas prácticas que aparecen en esta publicación en la cual participa el tutor de este PFG [28], y se obtuvieron unos resultados consistentes. Esto hizo que la parte experimental y la parte documental quedaran más conectadas de lo previsto inicialmente, obligando a extender el esfuerzo también en la fase de cierre del proyecto.

Se encontraron también dificultades generales con la programación, lo que, sumado al retraso acumulado desde el paquete PT1, supuso que hubiera que dedicar más horas diarias de lo previsto. Por suerte, esta ampliación de las horas diarias dedicadas, no solo mitigó el retraso previo, sino que además llevó a una disminución del tiempo total estimado al inicio para el desarrollo del paquete PT3, algo clave para no desviarse tanto del tiempo inicial estimado para la realización del PFG por completo.

El resto de los plazos tuvieron incidentes y condicionantes mínimos, propios de un proyecto, que permitieron seguir el flujo estipulado al comienzo del mismo.

5. RESULTADOS

En este capítulo se describen, interpretan y analizan críticamente los resultados obtenidos durante el desarrollo del proyecto. El objetivo principal de esta sección no es únicamente presentar las métricas finales del modelo de clasificación, sino demostrar en qué medida se han alcanzado los objetivos definidos, qué evidencias permiten validar la prueba de concepto y qué desviaciones se han producido respecto a los resultados esperados inicialmente.

El proyecto parte de una idea central: representar imágenes de resonancia magnética funcional mediante grafos cerebrales y utilizar dichas representaciones como entrada para modelos de Deep Learning basados en grafos. Para ello, se ha desarrollado un flujo completo que incluye la búsqueda y selección de datasets abiertos, el preprocesamiento de imágenes fMRI, la transformación de señales cerebrales en matrices de conectividad, la construcción de grafos, la visualización de las redes generadas y el entrenamiento de una GNN para una tarea de clasificación binaria entre sujetos control y pacientes con enfermedad de Parkinson.

Los resultados se presentan siguiendo una estructura alineada con los objetivos específicos del trabajo. En cada apartado se indica el resultado esperado, los resultados obtenidos, las evidencias utilizadas para validar el objetivo, las desviaciones producidas y el grado de cumplimiento alcanzado. De esta forma, el análisis no se limita a valorar el rendimiento final del modelo, sino que evalúa también la validez técnica del pipeline completo desarrollado.

5.1. OBJETIVO 1: ESTUDIO DE DATASETS ABIERTOS DISPONIBLES

El primer objetivo específico consistía en realizar un estudio de los datasets abiertos disponibles que pudieran utilizarse para desarrollar el caso de uso planteado. El resultado esperado era disponer de una revisión de los datasets seleccionados, indicando su procedencia, composición general, utilidad metodológica y criterio de incorporación al proyecto.

Este objetivo se ha alcanzado mediante la selección de varios conjuntos de datos abiertos relacionados con fMRI y enfermedad de Parkinson. Los datasets utilizados fueron Neurocon y varios datasets procedentes de OpenNeuro, concretamente ds004718, ds004392 y ds005892. Estos conjuntos fueron seleccionados porque permitían construir un caso de uso de clasificación binaria entre sujetos con Parkinson y sanos, aunque cada uno presentaba características y limitaciones distintas.

Durante el análisis de los datasets se observó que no todos los conjuntos tenían la misma utilidad metodológica. ds005892 y Neurocon contenían tanto sujetos control como sujetos pacientes, lo que los hacía especialmente útiles para estudiar diferencias dentro de un mismo origen de datos. En cambio, ds004718 aportaba principalmente sujetos control, mientras que ds004392 aportaba pacientes con Parkinson. Esta situación permitió aumentar el número

total de muestras, pero introdujo una dificultad importante y era el riesgo de que el modelo aprendiera diferencias entre datasets en lugar de diferencias asociadas a la condición clínica.

Tras generar las matrices de conectividad y filtrar únicamente aquellas con dimensión 116x116, se obtuvo la siguiente distribución inicial:

Clase	Dataset	Nº de muestras tras filtrado 116x116
Control	ds004718	46
Control	Neurocon	14
Control	ds005892	13
Patient	ds004392	55
Patient	Neurocon	25
Patient	ds005892	25

Tabla 2: Distribución inicial de muestras tras el filtrado 116x116. Fuente: Elaboración propia.

Esta distribución aparece directamente en el notebook final de la GNN. Tras el filtrado, el conjunto contenía 178 muestras, con 73 controles y 105 pacientes. El propio notebook imprime también las cuentas por dataset: 46 controles de ds004718, 14 de Neurocon, 13 de ds005892, 55 pacientes de ds004392, 25 de Neurocon y 25 de ds005892.

Para reducir el peso excesivo de algunos datasets, se aplicó un balanceo por dataset dentro de cada clase. La distribución final utilizada fue:

Clase	Dataset	Nº de muestras finales
Control	ds004718	13
Control	Neurocon	13
Control	ds005892	13
Patient	ds004392	25
Patient	Neurocon	25
Patient	ds005892	25

Tabla 3: Distribución final de muestras tras el balanceo por dataset. Fuente: Elaboración propia.

El balanceo se realizó en el propio notebook mediante una función específica que fija como objetivo 13 muestras para cada dataset de la clase control y 25 muestras para cada dataset de la clase patient. Este resultado permite reducir el sesgo interno por dataset, aunque no elimina completamente el desbalance global entre clases, ya que el conjunto final queda compuesto por 39 controles y 75 pacientes. Sin embargo, para solventar al máximo lo que esto puede provocar, se aplicó una estratificación.

El objetivo se considera cumplido, ya que se estudiaron e incorporaron datasets abiertos adecuados para el caso de uso y se analizaron sus limitaciones. La desviación principal fue que los datos disponibles no estaban equilibrados de forma natural, por lo que fue necesario aplicar un balanceo posterior y tener en cuenta esta limitación en la interpretación de los resultados.

Grado de cumplimiento: alto.

Evidencias: selección de datasets, filtrado 116x116, distribución inicial y distribución balanceada.

Desviación principal: heterogeneidad entre datasets y desbalance global residual.

5.2. OBJETIVO 2: TRANSFORMACIÓN DE fMRI EN GRAFOS

El segundo objetivo consistía en diseñar e implementar un método para convertir pruebas de imagen médica, principalmente fMRI, en grafos que permitieran estudiar la conectividad cerebral. El resultado esperado era disponer de un módulo funcional capaz de transformar una imagen funcional en una estructura de grafo correctamente definida.

Este objetivo se alcanzó mediante la integración de la funcionalidad fMRI dentro de la librería. El repositorio contiene los módulos `/eegraph` y `/mrigraph`, donde se organiza la lógica principal de carga, transformación, modelado, preprocesamiento, denoising, atlas, visualización y herramientas auxiliares. En concreto, `/eegraph` mantiene archivos como `graph.py`, `importData.py`, `modelateData.py`, `strategy.py` y `tools.py`, mientras que `/mrigraph` incluye módulos específicos como `atlas.py`, `config.py`, `denoise.py`, `importMRIData.py`, `modelateData.py`, `preprocess.py`, `strategy.py`, `tools.py` y `transform.py`. Se muestra a continuación una tabla de lo que hacen los módulos más importantes desarrollados.

Paso	Módulo principal	Qué hace
1	InputfMRIData	Carga el Nifti 4D, valida que la entrada tenga sentido y recoge metadatos y archivos auxiliares si existen.
2	PreprocessMRIData	Hace el preprocesado básico previo al modelado. Aquí la idea es dejar la señal en un formato consistente para seguir.
3	DenoiseMRIData	Aplica un denoising básico. Si hay confounds, se pueden usar; si no los hay, el flujo sigue sin bloquearse.
4	TransformMRIData	Resuelve el atlas, lo adapta al espacio del fMRI si hace falta, extrae la matriz ROI x tiempo y calcula centroides.
5	ModelMRIData	Calcula la matriz de conectividad a partir de las series temporales de las ROIs.
6	Construcción del grafo	Se crea el grafo final (con labels anatómicos reales para AAL), posiciones 3D, proyección 2D y profundidad para la visualización.

Tabla 4: Función de los módulos más importantes. Fuente: Elaboración propia.

Aunque por fuera el uso sea simple, por dentro la implementación fMRI ya sigue un flujo bastante claro y ordenado. El recorrido completo, simplificado, es este de aquí:

1. El usuario llama a `Graph.load_data(..., modality="fmri")`.
2. `graph.py` delega la carga en `InputfMRIData` dentro de `eegraph`.

3. Ese adaptador llama a `InputMRIData` dentro de `mrigraph`.
4. El resultado de la carga se guarda en un `MRInputBundle`.
5. El usuario llama a `Graph.modelate(...)`.
6. `graph.py` crea un `ModelMRIData`.
7. `ModelMRIData` ejecuta el pipeline interno:
 - a. Preprocess
 - b. Denoise
 - c. Transform
 - d. connectivity
8. Después construye el grafo final con etiquetas ROI, posiciones y metadatos.

El flujo que sigue un fMRI desde que lo introduce el usuario hasta que devuelve el grafo, de forma más detallada, se describe a continuación.

5.2.1. Flujo de transformación de fMRI a grafo

Este punto es el más útil para entender de verdad qué pasa cuando el usuario mete un fMRI. La idea no es bajar al detalle de cada línea, pero sí dejar claro por dónde entra el dato y qué responsabilidad tiene cada bloque, y validar por tanto el primer gran objetivo de este trabajo.

eeagraph/graph.py

El punto de entrada real es `Graph.load_data()`. Aquí se decide si el flujo será EEG o fMRI. Si la modalidad es fMRI, `graph.py` no intenta reutilizar la lógica antigua de EEG, sino que deriva la carga a `InputfMRIData`.

Después, cuando el usuario llama a `Graph.modelate()`, `graph.py` vuelve a actuar como capa de entrada. Si la modalidad es fMRI, crea un `ModelMRIData` y le pasa los parámetros necesarios. También guarda en `Graph.metadata` parte de los bundles intermedios para poder inspeccionar luego la transformación o la conectividad si hace falta.

En otras palabras, `graph.py` se ha quedado como fachada pública. No hace el trabajo duro de fMRI, pero sí es la puerta de entrada y el punto de unión con el comportamiento clásico de la librería.

eeagraph/importData.py -> clase InputfMRIData

`InputfMRIData` no es el loader de verdad, sino un adaptador. Su papel es recibir la llamada desde `Graph` y redirigirla a `mrigraph.importMRIData.InputMRIData`.

Las funciones clave aquí son `load()`, `display_info()`, `get_ch_names()` y `get_metadata()`. `load()` invoca la carga real. `display_info()` muestra un resumen útil en consola. `get_ch_names()` devuelve una lista vacía en esta fase, porque antes de aplicar un atlas todavía no existen etiquetas ROI reales. `get_metadata()` prepara un resumen cómodo para que `Graph` pueda guardar la información básica de entrada.

Este archivo está en eegraph porque la API pública sigue entrando por ahí. Si no existiera este adaptador, graph.py tendría que importar directamente piezas internas de mrigraph y la integración quedaría más mezclada.

mrigraph/importMRIData.py

Aquí empieza ya la carga MRI de verdad. InputMRIData.load() valida primero la entrada principal con _validate_main_input(). Después carga el NIfTI mediante load_nifti_file(), valida que realmente sea un fMRI 4D y extrae metadatos básicos.

Si el usuario ha pasado auxiliares, _load_auxiliary_files() los carga y los deja disponibles en el bundle. En el estado actual esos auxiliares son opcionales. De hecho, los tests finales mostraron que el pipeline sigue funcionando aunque no se pasen.

El resultado de esta fase es un MRIInputBundle. Ese bundle ya deja organizado el archivo principal, los metadatos y los auxiliares, pero todavía no hay preprocesado ni ROIs ni conectividad.

mrigraph/preprocess.py

PreprocessMRIData.run() trabaja ya con la imagen cargada. Primero comprueba que el bundle de entrada sea válido. Luego extrae el contenido numérico del NIfTI a un array con _extract_fmri_array() y valida que siga teniendo la forma esperada.

Después aplica un preprocesado básico y honesto: reemplaza valores no finitos con _replace_non_finite_values(), puede normalizar los datos con _normalize_data() y prepara una vista voxel x tiempo con _reshape_to_voxel_time_series().

Es importante remarcar que esta fase no pretende competir con pipelines completos de neuroimagen. Aquí se ha optado por una fase útil, clara y suficiente para llegar al modelado de conectividad.

mrigraph/denoise.py

DenoiseMRIData.run() parte del bundle de preprocess. Valida primero la entrada y luego intenta localizar una matriz de confounds con _find_confounds_matrix(). Si la encuentra y la configuración lo permite, aplica una regresión básica de confounds con _regress_confounds().

Después reconstruye el volumen 4D con _reshape_to_4d() y empaqueta todo en un MRIDenoiseBundle. Igual que antes, aquí el enfoque ha sido funcional y sincero: se deja la puerta abierta a mejoras futuras, pero no se maquilla como si ya existiera un denoising clínico completo.

En la práctica, esta fase es la que prepara la señal para que la transformación a ROI se haga sobre una versión más limpia que la salida directa del NIfTI.

mrigraph/transform.py

TransformMRIData.run() es probablemente la pieza más delicada de toda la ampliación. Aquí se pasa del volumen denoised 4D a una matriz ROI x tiempo. Primero se valida el bundle de denoising y se obtiene la affine del fMRI.

Después `_resolve_atlas()` decide qué atlas se va a usar. Puede venir directamente, puede resolverse por nombre desde la configuración o detectarse entre auxiliares. Si el atlas no está en el mismo espacio o grid, `_prepare_atlas_for_fmri_space()` y `_resample_atlas_to_fmri_space()` se encargan de adaptarlo.

Una vez resuelto el atlas, `_get_valid_roi_ids()` obtiene las regiones válidas, `_build_roi_labels()` construye las etiquetas que se verán luego en el grafo y `_extract_roi_time_series()` saca la media temporal de cada ROI.

Además, esta fase genera centroides 3D. Ahora ya no se quedan en coordenadas voxel como al principio, sino que pueden calcularse en coordenadas mundo cuando hay affine disponible. Eso era importante para que la visualización no quedara anatómicamente engañosa. También se ha dejado una caché de centroides en JSON para los casos en que no hay resampling y sí conviene reutilizar posiciones ya calculadas.

En resumen, `transform.py` es la pieza que une señal, atlas, ROIs y posición anatómica.

`mrigraph/modelateData.py`

Aunque el nombre pueda recordar a la parte antigua de `EEGraph`, aquí el papel es más concreto: `ModelMRICnectivityData.run()` recibe el `MRITransformBundle`, selecciona una estrategia de conectividad y calcula la matriz ROI x ROI.

Primero valida que exista `roi_time_series` y que tenga la forma correcta. Luego llama a `get_connectivity_strategy()`, calcula la conectividad y, si el usuario ha puesto `threshold`, aplica el umbral. El resultado se guarda en un `MRICnectivityBundle` junto con metadatos útiles como el número de ROIs, el tamaño de la matriz o si la matriz es simétrica.

Esta fase cierra la parte numérica del pipeline. A partir de aquí ya se puede construir el grafo.

`mrigraph/strategy.py` y `mrigraph/tools.py`

`strategy.py` se encarga de elegir la estrategia de conectividad según el nombre que haya pedido el usuario. Es una capa sencilla, pero útil porque deja desacoplada la selección del método respecto al cálculo real.

El cálculo numérico está en `tools.py`. Ahí se validan los nombres, se mantienen los alias y se implementan las medidas soportadas. En el estado actual quedan registradas Pearson, cross correlation y corrected.

El motivo de mantener esta separación es que así añadir o quitar métodos en el futuro es bastante más limpio.

`eegraph/modelateData.py` -> clase `ModelMRIData`

Esta clase es el orquestador real del flujo MRI desde la parte pública de `EEGraph`. `connectivity_workflow()` recibe el `MRInputBundle` y va llamando, por orden, a `PreprocessMRIData`, `DenoiseMRIData`, `TransformMRIData` y `ModelMRICnectivityData`.

Cuando ya tiene la matriz de conectividad, elimina la diagonal para que en la visualización si el usuario le da a “Show Edge Markers” no se vean los nodos como “edge markers” también,

actualiza `ch_names` con las etiquetas ROI reales y construye el grafo final con `_build_graph_from_matrix()`.

Este método también decide cómo proyectar las posiciones 3D a 2D para poder visualizar el grafo. En el estado actual se está usando proyección axial y la profundidad se codifica aparte para usarla luego en color.

eegraph/tools.py

`draw_graph()` es la pieza que finalmente visualiza el resultado. Lo importante es que, si el grafo ya trae posiciones precomputadas, se respetan y no se fuerza el layout EEG.

`is_fmri_graph()` permite detectar si el grafo es MRI sin depender ya de nombres tipo ROI_xx. `get_node_trace()` utiliza la profundidad para colorear los nodos y mostrar una barra de color, y `get_edge_trace()` se ha suavizado para que las aristas no tapen toda la figura.

Esta parte fue importante porque, aunque la conectividad ya salía, la visualización al principio no era fiable ni legible. Ahora al menos queda una representación 2D razonable y entendible para el alcance del trabajo.

Siendo capaces de demostrar este flujo, se da por validada esta parte de transformación de fMRI en grafos.

El ejemplo `Examples/NEW_ejemplo_uso_fmri.ipynb` actúa como evidencia directa de uso de la librería. En él se muestra el flujo mínimo para fMRI: crear un objeto `Graph()`, cargar los datos con `load_data(..., modality="fmri")`, crear una configuración de atlas mediante `AtlasConfig`, llamar a `modelate(...)` e inspeccionar `Graph.metadata` para recuperar trazabilidad del pipeline.

En la práctica, la transformación genera una matriz de conectividad y un grafo. El ejemplo de uso ejecuta `G.modelate(...)` con conectividad pearson, un threshold y un atlas_config, y después muestra la forma de la matriz de conectividad, el número de nodos y el número de aristas del grafo resultante. Esto demuestra que la librería no solo carga una imagen, sino que produce una representación computacional reutilizable en forma de red cerebral. Se muestra a continuación una tabla con estos resultados generados y su función en el flujo.

Resultado generado	Función dentro del flujo
Matriz de conectividad	Representa relaciones funcionales entre regiones cerebrales
Grafo cerebral	Representa regiones como nodos y conexiones como aristas
Metadatos	Permiten mantener trazabilidad del pipeline
Visualizaciones	Permiten inspeccionar visualmente la red generada

Tabla 5: Resultados de la transformación de fMRI a grafo. Fuente: Elaboración propia.

El objetivo se considera cumplido porque la librería permite transformar datos fMRI en matrices de conectividad y grafos cerebrales. La principal desviación fue que, para la GNN final, solo se conservaron matrices de dimensión 116x116, ya que el modelo necesitaba entradas homogéneas.

Grado de cumplimiento: alto.

Evidencias: módulos `/eegraph` y `/mrigraph`, ejemplo `NEW_ejemplo_uso_fmri.ipynb`, generación de matrices y grafos.

Desviación principal: necesidad de filtrar matrices para asegurar una dimensión homogénea de entrada.

5.3. OBJETIVO 3: PREPROCESAMIENTO DE LOS DATOS DE ENTRENAMIENTO

El tercer objetivo consistía en realizar el preprocesamiento de los datos de entrenamiento utilizando al menos uno de los datasets seleccionados. El resultado esperado era obtener un conjunto de datos preparado para la transformación posterior a grafos y para el entrenamiento de la red neuronal.

Este objetivo se alcanzó mediante el script `preprocesamiento_gnn_fmri.py`. Este script implementa un flujo completo que parte de fMRIs en una carpeta de entrada, genera datos preprocesados, transforma posteriormente cada fMRI a grafo y guarda salidas reutilizables para la GNN.

Un aspecto técnico importante fue el tratamiento de imágenes 4D. Las fMRIs contienen tres dimensiones espaciales y una dimensión temporal. Durante el desarrollo se detectó que determinadas operaciones espaciales podían fallar al aplicarse directamente sobre imágenes 4D. Para resolverlo, el script incorpora una estrategia de resamplado volumen a volumen, manteniendo después la estructura 4D. Esta solución queda reflejada en el paso `common_voxel_resampling_4d_volume_by_volume`.

El script también evita mezclar datos raw con derivados ya preprocesados por terceros. En la búsqueda de BOLD válidos se ignoran carpetas no deseadas y se excluyen archivos cuyo nombre contenga términos como `desc-preprocessed`, `preprocessed`, `preproc`, `denoised` o `smoothed`. Esto es metodológicamente importante porque permite mantener un flujo homogéneo sobre los datos seleccionados, y los datasets seleccionado contenían archivos como los que se mencionan.

Además, tras preprocesar cada fMRI, el script llama a la transformación con `Graph().load_data(..., modality="fmri")` y `G.modelate(...)`. Como el fMRI ya ha pasado por el preprocesamiento externo, el script desactiva pasos internos equivalentes en `PreprocessConfig` y `DenoiseConfig`, evitando duplicar transformaciones. Finalmente, guarda el grafo, la matriz de conectividad, el HTML, metadatos y un `qc_report.json` a nivel de control de calidad. Se muestra a continuación una tabla con las salidas generadas y su significado.

Salida del preprocesamiento/transformación	Descripción
fMRI preprocesado	Imagen funcional preparada para la extracción de conectividad
grafo_fmri.pkl	Grafo serializado
connectivity_matrix_fmri.npz	Matriz de conectividad funcional
fmri_grafo_plot.html	Visualización interactiva
metadata_transformacion.json	Metadatos del proceso
qc_report.json	Control de calidad del preprocesamiento

Tabla 6: Salidas generadas por preprocesamiento_gnn_fmri.py. Fuente: Elaboración propia.

El objetivo se considera cumplido, ya que se desarrolló un flujo reproducible de preprocesamiento y transformación. La principal desviación fue el aumento del coste computacional, ya que al procesar imágenes 4D volumen a volumen, el tiempo por archivo aumentó considerablemente, haciendo que solamente el preprocesamiento de los datasets seleccionados durase en torno a 15 horas. Esta desviación fue asumida como necesaria para conservar la dimensión temporal de la señal fMRI.

Grado de cumplimiento: alto.

Evidencias: script preprocesamiento_gnn_fmri.py, tratamiento 4D, exclusión de derivados, generación de QC, matrices y grafos.

Desviación principal: mayor coste computacional y necesidad de gestionar espacio en disco.

5.4. OBJETIVO 4: ENTRENAMIENTO DE MODELOS DE DEEP LEARNING

El cuarto objetivo consistía en entrenar uno o varios modelos de Deep Learning para resolver un caso de uso médico concreto a partir de los datos procesados. El resultado esperado era disponer de un modelo entrenado capaz de utilizar grafos cerebrales como entrada para una tarea de clasificación.

Este objetivo se alcanzó mediante el notebook GNN_neurocon_para_test.ipynb. Este notebook carga las matrices de conectividad de los datasets desde las carpetas a/graphs_threshold05/parkinson_control y a/graphs_threshold05/parkinson_patient, identifica el dataset de origen de cada muestra, filtra matrices 116x116, aplica balanceo por dataset y separa Neurocon como conjunto de test externo. Se transformaron los datasets con un umbral de 0.3, 0.5 y 0.7, y se hicieron pruebas con los 3 conjuntos de datasets, pero finalmente se han utilizado los grafos generados con threshold = 0.5. El umbral lo que hace es filtrar únicamente las conexiones superiores al valor seleccionado.

La conversión de matrices a grafos se realiza limpiando la matriz de conectividad, simetrizándola, eliminando la diagonal y gestionando los valores negativos. En la

configuración final USAR_ABSOLUTO = False, por lo que las correlaciones negativas se sustituyen por cero en lugar de transformarse en valores positivos. Después, las aristas se construyen seleccionando los K_VECINOS más conectados por nodo, con K_VECINOS = 20.

La arquitectura final es una GNN del tipo GCN binaria con tres capas convolucionales (GCNConv). Después de las convoluciones se aplican activaciones ReLU, dropout y una combinación de global_mean_pool y global_max_pool. Finalmente, se utiliza una capa fully connected para producir una salida binaria.

La combinación final de hiperparámetros de redes neuronales utilizada fue:

Hiperparámetro	Valor
Épocas máximas	100
Paciencia	10
Learning rate	0.0005
Weight decay	0.0001
Usar valor absoluto	False
K vecinos	20
Hidden dim	16
Dropout	0.6
Umbral de clasificación	0.5
Batch size	32
Semilla	168

Tabla 7: Combinación final de hiperparámetros. Fuente: Elaboración propia.

El entrenamiento utiliza BCEWithLogitsLoss con pos_weight, calculado a partir de la proporción entre negativos y positivos del conjunto de entrenamiento. También utiliza Adam como optimizador, early stopping con paciencia 10 y como criterio de mejora y selección del mejor estado del modelo según F1 de validación, usando AUC como criterio de desempate cuando el F1 es equivalente.

La semilla se utiliza para que la división se haga siempre de forma aleatoria pero con el mismo reparto de archivos, y se pueda probar siempre sobre la misma división. Por tanto, para comprobar la fiabilidad de los resultados, hay que aplicar cross-validation.

El objetivo se considera cumplido, ya que se entrenó una GNN funcional sobre grafos cerebrales generados previamente. La desviación principal es que el entrenamiento no resolvió por completo el problema de generalización ni eliminó el sesgo hacia la clase patient, como se observa en los resultados del objetivo 5.

Grado de cumplimiento: alto.

Evidencias: notebook GNN_neurocon_para_test.ipynb, arquitectura GCN, hiperparámetros, early stopping y entrenamiento completado.

Desviación principal: rendimiento moderado y tendencia del modelo hacia la clase positiva.

5.5. OBJETIVO 5: EVALUACIÓN CUANTITATIVA DEL RENDIMIENTO DEL MODELO

El quinto objetivo consistía en evaluar el rendimiento del modelo mediante métricas matemáticas adecuadas para el problema planteado. El resultado esperado era obtener un informe con métricas como accuracy, recall, F1-score, AUC y matriz de confusión.

Este objetivo se cumplió mediante el cálculo de métricas en train, eval y test. Los resultados finales del notebook fueron:

Conjunto	Loss	Accuracy	Recall	F1-score	AUC
Train	0.4723	0.6667	0.7179	0.7368	0.6777
Eval	0.4565	0.9375	1.0000	0.9565	0.8182
Test	0.4291	0.7632	0.9200	0.8364	0.7231

Tabla 8: Resultados finales de la GNN. Fuente: Elaboración propia.

El conjunto de test es el resultado más relevante, ya que corresponde a Neurocon, separado como test externo. En este conjunto, el modelo alcanzó una accuracy de 0.7632, un recall de 0.9200, un F1-score de 0.8364 y un AUC de 0.7231. El notebook muestra estos valores, junto con la matriz de confusión.

La matriz de confusión de test obtenida fue:

	Predicho control	Predicho patient
Real control	6	7
Real patient	2	23

Tabla 9: Matriz de confusión del conjunto de test. Fuente: Elaboración propia.

A partir de esta matriz se observa que el modelo clasificó correctamente 23 de los 25 pacientes, pero solo 6 de los 13 controles. Esto significa que el modelo presenta una alta sensibilidad para la clase patient, pero una baja especificidad para la clase control. Por tanto, Las métricas derivadas de la matriz son:

Métrica derivada	Cálculo	Valor
Sensibilidad patient	23 / 25	0.9200
Especificidad control	6 / 13	0.4615
Precision patient	23 / 30	0.7667
Balanced accuracy	$(0.9200 + 0.4615) / 2$	0.6908

Tabla 10: Métricas derivadas de la matriz de confusión. Fuente: Elaboración propia.

El acierto global de 0.7632 debe interpretarse teniendo en cuenta la composición del test. La división final muestra 38 muestras de test: 13 controles y 25 pacientes. Por tanto, un clasificador que predijera siempre patient alcanzaría $25/38 = 0.6579$ de accuracy. El modelo supera esa base, pero la mejora debe considerarse moderada, especialmente porque la especificidad de controles es baja.

La distribución de archivos fue la siguiente:

Conjunto	Total	Control	Patient
Train	60	21	39
Eval	16	5	11
Test	38	13	25

Tabla 11: Distribución de train, eval y test. Fuente: Elaboración propia.

El resultado en evaluación es muy alto, con accuracy 0.9375 y F1-score 0.9565. Sin embargo, al compararlo con test, se observa una caída de rendimiento. Esto indica que el conjunto de evaluación resultó más favorable que Neurocon-test, o que la generalización a un dataset externo es más difícil.

Se muestran a continuación las curvas de las métricas obtenidas en el experimento final de la GNN.




Figura 5: Matriz de confusión. Fuente: Elaboración propia.




Figura 6: Curva de accuracy. Fuente: Elaboración propia.




Figura 7: Curva de f1-score. Fuente: Elaboración propia.




Figura 8: Curva de AUC. Fuente: Elaboración propia.

Además de la evaluación final sobre el conjunto de test, se realizó una validación cruzada con $k = 5$ particiones. Esta prueba se incorporó como análisis complementario para comprobar la estabilidad del modelo y reducir la dependencia de una única división de los datos. En este tipo de validación, el conjunto disponible se divide en cinco subconjuntos o folds, de manera que el modelo se entrena y evalúa varias veces utilizando diferentes particiones. Esto permite obtener una estimación más robusta del rendimiento medio.

Los resultados obtenidos fueron los siguientes:

Validación cruzada	Valor
Número de folds	5
Accuracy media en test	0.6632
Desviación típica	0.0105

Tabla 12: Resultado de la validación cruzada con $k = 5$. Fuente: Elaboración propia.

La accuracy media obtenida fue de 0.6632, con una desviación típica de 0.0105. Este resultado indica que el rendimiento medio del modelo en validación cruzada se sitúa en torno al 66,32%. La desviación típica es baja, por lo que el comportamiento del modelo resulta relativamente estable entre particiones. Sin embargo, el valor medio es inferior al obtenido en el test final, donde la accuracy fue de 0.7632.

Esta diferencia entre el resultado puntual del test y la validación cruzada es importante para la interpretación del modelo. El test final muestra que la configuración seleccionada puede alcanzar un rendimiento aceptable sobre Neurocon, especialmente por su alto recall en la clase patient. No obstante, la validación cruzada ofrece una estimación más conservadora de

la capacidad de generalización del modelo. Por tanto, los resultados no deben interpretarse únicamente a partir de la mejor partición, sino considerando también que el rendimiento medio en distintas divisiones es más moderado.

En consecuencia, la validación cruzada refuerza la conclusión de que la GNN aprende cierta información útil a partir de los grafos generados, pero que su capacidad de generalización todavía es limitada. El modelo supera el rendimiento aleatorio, pero no alcanza una robustez suficiente como para considerarse una herramienta diagnóstica validada. Esta prueba aporta una evidencia adicional para considerar cumplido el objetivo de evaluación cuantitativa, ya que no solo se han calculado métricas finales de clasificación, sino también una estimación de estabilidad mediante validación cruzada.

El resultado esperado no era necesariamente obtener un modelo clínicamente perfecto, sino comprobar la viabilidad técnica del flujo. El modelo obtiene resultados superiores al azar y detecta bien sujetos con enfermedad de Parkinson aunque presenta baja especificidad en controles, por lo que la prueba de concepto se valida técnicamente, aunque no clínicamente.

El objetivo por tanto se considera cumplido porque se calcularon e interpretaron métricas adecuadas. La desviación principal es que el rendimiento no es equilibrado entre clases. El modelo detecta muy bien pacientes, pero confunde una proporción importante de controles como pacientes.

Grado de cumplimiento: alto.

Evidencias: métricas train/eval/test, matriz de confusión, classification report y CSVs guardados.

Desviación principal: alta sensibilidad, pero baja especificidad.

5.6. OBJETIVO 6: INTEGRACIÓN DE LOS MÓDULOS EN UNA LIBRERÍA FUNCIONAL

El séptimo objetivo consistía en integrar todos los módulos desarrollados en una única librería funcional, que permitiera que cualquier persona pueda transformar un archivo fMRI en un grafo.

Este objetivo se considera cumplido. Se ha subido a la librería EEGraph la versión desarrollada en este trabajo, dejando por tanto una librería funcional que amplía la funcionalidad ya existente de transformar electroencefalogramas en grafos. De esta manera conseguimos que cualquier persona pueda transformar en grafos fMRIs o EEGs simplemente modificando el parámetro “modality” y añadiendo/quitando configuraciones como la del atlas que no proceden en la parte de EEGs. En el repositorio aparece también un ejemplo de uso de la librería con esta nueva actualización.

El objetivo se considera alcanzado porque existe una cadena completa desde datos fMRI hasta grafos y entrenamiento de una GNN. No se han encontrado desviaciones para este objetivo, y se valora la opción de añadir el script de preprocesamiento también a la librería,

permitiendo que el usuario pueda utilizarlo si tiene un objetivo que requiere estandarización de varios archivos fMRI.

Si se decide añadir este archivo, quedaría un flujo final con la siguiente estructura:

Fase	Entrada	Salida
Carga	fMRI	Objeto cargado con Graph.load_data
Configuración	Atlas y parámetros	AtlasConfig y configuración de modelado
Modelado	fMRI cargado	Matriz de conectividad y grafo
Visualización	Grafo	HTML/PNG
Preprocesamiento externo	fMRI raw	fMRI preprocesado + QC
Transformación masiva	fMRI preprocesado	Grafos y matrices para GNN

Tabla 13: Flujo funcional integrado en la librería. Fuente: Elaboración propia.

Grado de cumplimiento: alto.

Evidencias: estructura del repositorio, módulos /eegraph y /mrigraph, ejemplo fMRI, script de preprocesamiento y notebook de GNN.

Desviación principal: la librería es funcional para la prueba de concepto, pero todavía puede mejorar en empaquetado, automatización y documentación.

5.7. VALORACIÓN GLOBAL DE LA PRUEBA DE CONCEPTO

Antes de valorar los resultados obtenidos, es importante contextualizar el interés clínico del caso de uso planteado.

Actualmente, el diagnóstico de la enfermedad de Parkinson continúa siendo principalmente clínico, ya que no existe una única prueba de sangre o de imagen que confirme por sí sola la enfermedad. El diagnóstico se apoya en la historia clínica, la exploración neurológica, la evolución de los síntomas y, en determinados casos, en pruebas complementarias como la resonancia magnética o el DaTscan para descartar otras causas. [29], [30], [31]

En cuanto al tiempo necesario para confirmarlo, no existe una duración fija, ya que depende de la forma de presentación de la enfermedad, del seguimiento clínico y del especialista que valore al paciente. En cohortes recientes, el tiempo autorreportado desde el primer síntoma motor hasta el diagnóstico fue de aproximadamente 0,9, 1,1 y 1,0 años en PPMI, ICEBERG y LuxPARK, respectivamente. Otros trabajos han observado que, aunque muchos pacientes alcanzan un diagnóstico clínico final en los primeros meses, en algunos casos el proceso puede demorarse varios años. [32], [33]

Respecto a la fiabilidad, la literatura muestra que la exactitud del diagnóstico clínico no es perfecta, especialmente en fases iniciales. Una revisión sistemática con metaanálisis

concluyó que la validez global del diagnóstico clínico de Parkinson no resulta completamente satisfactoria, y trabajos posteriores resumen que la exactitud en diagnósticos hechos principalmente por no expertos fue de 73.8%. Y en especialistas en trastornos del movimiento puede situarse alrededor del 80% en la evaluación inicial y mejorar hasta aproximadamente el 84% tras el seguimiento. [34], [35]

Por ello, el desarrollo de modelos automáticos de apoyo tiene sentido clínico como línea de investigación, ya que puede aportar una capa objetiva adicional de análisis a partir de datos de neuroimagen. No obstante, estos modelos deben entenderse como herramientas experimentales de apoyo y no como sustitutos del diagnóstico médico realizado por especialistas.

En este contexto, la prueba de concepto desarrollada en este trabajo no pretende sustituir el diagnóstico médico ni ofrecer una herramienta clínica validada, sino explorar si la conectividad funcional extraída de fMRIs puede representarse mediante grafos y utilizarse como entrada para modelos automáticos de clasificación. Por tanto, los resultados obtenidos deben interpretarse como una validación técnica y experimental del pipeline, no como una validación clínica.

A partir de los resultados obtenidos, la prueba de concepto puede considerarse válida desde el punto de vista técnico. El proyecto demuestra que es posible partir de imágenes fMRI, aplicar un flujo de preprocesamiento, transformarlas en matrices de conectividad funcional, construir grafos cerebrales y entrenar una red neuronal de grafos sobre dichas representaciones.

La prueba de concepto responde afirmativamente a las siguientes preguntas:

Pregunta de validación	Resultado
¿Se pueden transformar fMRIs en grafos cerebrales?	Sí
¿Se pueden generar matrices homogéneas?	Sí
¿La librería permite ejecutar el flujo mediante una API reutilizable?	Sí
¿La GNN puede entrenarse con los grafos generados?	Sí
¿El modelo supera al azar en test externo Neurocon?	Sí
¿El modelo detecta correctamente la mayoría de pacientes?	Sí
¿El modelo clasifica controles con suficiente fiabilidad?	Parcialmente
¿El sistema puede considerarse clínicamente validado?	No

Tabla 14: Valoración global de la prueba de concepto. Fuente: Elaboración propia.

El resultado final de la GNN en test fue una accuracy de 0.7632, recall de 0.9200, F1-score de 0.8364 y AUC de 0.7231. Estos valores muestran que el modelo aprende patrones útiles a partir de los grafos, especialmente para detectar pacientes. Sin embargo, la matriz de confusión muestra una limitación importante: 7 de los 13 controles fueron clasificados erróneamente como pacientes.

En consecuencia, el proyecto no debe presentarse como una herramienta diagnóstica cerrada, sino como una prueba de concepto técnica y experimental. La principal aportación

es haber integrado neuroimagen funcional, conectividad cerebral, representación mediante grafos y redes neuronales de grafos en un mismo flujo reproducible. La parte predictiva muestra resultados prometedores, pero todavía moderados y condicionados por el desbalance de clases, el tamaño muestral y la heterogeneidad entre datasets.

A continuación, se muestra un resumen de los objetivos específicos planteados, los métodos de validación para cada uno, la evidencia de que se han cumplido y el grado de cumplimiento:

Objetivo	Resultado esperado	Evidencia	Grado de cumplimiento
Obj. 1	Estudio de datasets	Tablas de distribución	Alto
Obj. 2	Transformar fMRI en grafos	Matrices/grafos/ejemplo	Alto
Obj. 3	Preprocesamiento	preprocesamiento_gnn_fmri.py, QC	Alto
Obj. 4	Entrenar GNN	Notebook y modelo final	Alto
Obj. 5	Evaluar métricas	Accuracy, recall, F1, AUC, CV	Alto
Obj. 6	Integración librería	/eegraph, /mrigraph, ejemplo	Alto

Tabla 15: tabla resumen objetivo por objetivo. Fuente: Elaboración propia.

6. IMPLICACIONES ÉTICAS E IMPACTO SOCIAL

6.1. INTRODUCCIÓN

Este proyecto parte de una librería que originalmente estaba pensada para transformar señales EEG en grafos cerebrales, y se amplía para que también pueda trabajar con datos de fMRI. A partir de esos grafos, además, se plantea el uso de una red neuronal para grafos para analizar la información mediante técnicas de Deep Learning. Aunque se trata de un trabajo con un claro carácter de investigación y desarrollo, no deja de situarse en un ámbito especialmente delicado, ya que trabaja con información relacionada con el cerebro y con técnicas de inteligencia artificial.

Es por eso que no basta con valorar si el proyecto funciona y es viable desde un punto de vista técnico, también es necesario analizar qué aporta realmente, a quién puede beneficiar, qué riesgos puede generar y qué medidas conviene tomar para que su desarrollo y su uso en el futuro sean responsables. Este análisis es especialmente importante en un proyecto como este, ya que la tecnología aplicada al ámbito biomédico puede influir en futuras investigaciones, en la forma de interpretar resultados, y en decisiones relacionadas con la salud.

6.2. MARCO ÉTICO Y LEGAL

Desde el punto de vista ético, la referencia principal de este proyecto es el Código de Ética y Conducta Profesional de la ACM [36]. Este código insiste en ideas que encajan muy bien con el sentido del trabajo realizado: contribuir al bienestar humano, evitar daños, respetar la privacidad, realizar evaluaciones rigurosas de los sistemas y de sus riesgos... En un proyecto como este, esos principios obligan a actuar con prudencia, a no exagerar el alcance de los resultados, y a dejar claro que una herramienta de análisis no debe presentarse como si fuese una solución clínica cien por cien perfecta.

En el plano legal, el marco más importante viene dado por la normativa de protección de datos y por la normativa específica sobre inteligencia artificial. En relación con los datos, deben tenerse presentes el Reglamento General de Protección de Datos [37] y la Ley Orgánica 3/2018 [38], especialmente en todo lo relativo al tratamiento de información personal. Además, al tratarse de un proyecto que incorpora IA, también es necesario tener en cuenta el Reglamento (UE) 2024/1698 [39], que adopta un enfoque basado en el riesgo y que ya tiene parte de sus obligaciones antes incluso de su despliegue completo.

Aunque este PFG no se plantea como un producto sanitario ni como una herramienta asistencial lista para usarse en hospitales desde su lanzamiento, el hecho de trabajar con IA, aplicándola a información cerebral, hace recomendable asumir desde el diseño criterios de transparencia, prudencia, control de riesgos y definición clara de los límites del desarrollo.

En este sentido, debe dejarse explícito que la herramienta no sustituye el criterio clínico, no realiza diagnósticos médicos por sí sola y se enmarca en un contexto de investigación y apoyo al análisis, no de toma automática de decisiones sanitarias.

6.3. VALOR DEL PROYECTO

El principal valor del proyecto está en que no se limita a hacer un experimento aislado, sino que amplía una herramienta ya existente para que pueda utilizarse también en un nuevo tipo de datos. Eso tiene importancia y un gran valor, porque aporta continuidad y reutilización. De esta manera, en lugar de crear una solución cerrada para un único caso, se construye una base que puede servir a otras personas en trabajos posteriores.

Además, el proyecto aporta interés académico y científico, porque propone una forma distinta de analizar fMRIs. En lugar de tratar el cerebro como una imagen, lo representa como una red de regiones conectadas entre sí. Este enfoque encaja mejor con la propia naturaleza del cerebro, y abre las puertas a nuevas formas de análisis apoyadas en grafos y en técnicas de Deep Learning.

También tiene un valor formativo y profesional, ya que no solo exige resolver un problema técnico, sino hacerlo de forma ordenada, documentada, y pensando en sus posibles implicaciones. Por ello, el proyecto no aporta únicamente una solución técnica, sino también una base útil para futuros trabajos en este ámbito.

6.4. ALCANCE DEL PROYECTO

Este proyecto se sitúa en el ámbito de la investigación y del desarrollo de herramientas de apoyo de análisis de neuroimagen. Su finalidad no es realizar diagnósticos clínicos ni sustituir el criterio de profesionales sanitarios, sino ofrecer una base técnica que permita transformar datos de fMRI en grafos y analizarlos posteriormente mediante redes neuronales sobre grafos.

Las personas afectadas de forma más directa por el proyecto son quienes utilicen la librería o consulten sus resultados: desarrolladores, investigadores y posibles equipos académicos que se apoyen en esta herramienta para continuar una línea de trabajo. De forma indirecta, también puede afectar a pacientes, profesionales sanitarios o instituciones de investigación, en la medida en que este tipo de herramientas contribuya en el futuro a mejorar métodos de análisis o a generar nuevo conocimiento.

6.5. RESPONSABILIDAD E IMPACTO

Desde el punto de vista del propio proyecto, uno de los aspectos más delicados es el tratamiento de los datos. Aunque se trabaje con conjuntos de datos públicos o anonimizados, la información cerebral sigue siendo especialmente sensible, por lo que debe tratarse con

prudencia, evitando el uso de datos innecesarios y respetando siempre la normativa de protección de datos.

Otro riesgo importante es interpretar los resultados de forma exagerada. Que un modelo encuentre patrones en los datos no significa que pueda sustituir una valoración clínica ni que sus conclusiones sean válidas e irrefutables en cualquier contexto. Por ello, es fundamental presentar la herramienta como un apoyo a la investigación, no como un sistema automático de diagnóstico.

Más allá de los aspectos técnicos, el proyecto puede tener un impacto social positivo porque facilita el desarrollo de nuevas investigaciones y fomenta el uso de herramientas reutilizables en un ámbito con gran interés científico. Sin embargo, también puede tener consecuencias negativas si se genera una confianza excesiva en la IA o si se transmite una idea simplificada del funcionamiento del cerebro. Por esto, otra parte esencial de la responsabilidad del proyecto está en comunicar con claridad sus posibilidades reales y también sus límites.

En el plano económico, reutilizar una librería ya existente y ampliarla puede ahorrar tiempo y recursos en trabajos futuros. En cuanto al impacto medioambiental, aunque no se trata de un proyecto a gran escala, conviene tener presente que el entrenamiento de modelos de Deep Learning implica consumo computacional, por lo que resulta razonable evitar experimentos innecesarios y trabajar de la forma más eficiente posible.

Con el fin de recoger de forma clara y exhaustiva los principales riesgos identificados en este proyecto, se incluye a continuación un Registro de Riesgos elaborado para este proyecto. Para cada riesgo se indica un código, una breve descripción, su probabilidad, su impacto y la medida prevista para evitarlo, minimizarlo o mantenerlo bajo control. Esta tabla con el detalle se encuentra en [Anexo C: Registro de Riesgos](#), pero se muestra a continuación un resumen.

Probabilidad \ Impacto	Bajo	Medio	Alto
Alta	—	—	R3, R4
Media	—	R7, R8	R1, R2, R5, R6
Baja	—	R9, R10	—

Tabla 16: Matriz de Riesgos del proyecto. Fuente: Elaboración propia.

6.6. CONCLUSIONES

Tras este análisis, puede afirmarse que el proyecto presenta un valor claro desde el punto de vista académico, científico y social. Su principal aportación no está en prometer soluciones inmediatas, sino en construir una herramienta útil, reutilizable y bien orientada para futuras investigaciones en neuroimagen y aprendizaje sobre grafos.

Los riesgos identificados existen, pero no convierten al proyecto en éticamente inviable. Como se recoge en el Registro de Riesgos, los principales aspectos críticos están relacionados

con el tratamiento responsable de datos sensibles, la interpretación de los resultados, la dependencia metodológica respecto a datasets, atlas y decisiones de preprocesado, y el posible uso indebido de la herramienta fuera de un contexto de investigación. No obstante, todos ellos pueden prevenirse, minimizarse o mantenerse bajo control mediante medidas razonables de documentación, prudencia, validación y delimitación del alcance del sistema.

En relación con todo lo expuesto, dado el valor que presenta el proyecto y que los riesgos detectados pueden evitarse, minimizarse o mantenerse bajo control con medidas adecuadas, podemos concluir que el proyecto no solamente es viable desde el punto de vista ético, sino que además es recomendable llevarlo a cabo. También debe reconocerse que los resultados obtenidos dependen del conjunto de datos utilizado, del atlas elegido y de las decisiones de preprocesado aplicadas, por lo que sus conclusiones deben interpretarse siempre dentro de ese marco concreto.

7. MI RECORRIDO EN LA UFV

7.1. EL PFG COMO CULMINACIÓN DE MI CAMINO UNIVERSITARIO

Cuando llegué a la Universidad Francisco de Vitoria, lo hice con mucha ilusión y con la sensación de estar comenzando una etapa muy importante de mi vida. Tenía bastante claro desde hacía muchos años que quería estudiar Ingeniería Informática, así que entrar en la carrera suponía, de alguna manera, empezar a recorrer un camino que llevaba tiempo imaginando. También me hacía especial ilusión estudiar en esta universidad, en parte por la buena experiencia que había vivido aquí mi hermana. Aun así, el inicio imponía respeto: empezar una carrera, conocer gente nueva y adaptarse a un entorno distinto siempre da vértigo. Además, fueron unos comienzos marcados por la situación del COVID, lo que hizo todavía más extraño ese primer contacto con la vida universitaria. A pesar de ello, recuerdo esa etapa sobre todo como un momento de muchas ganas: ganas de aprender, de conocer gente nueva, de estudiar por fin aquello que realmente me gustaba y de comenzar la última gran etapa de mi vida como estudiante.

Elegí esta carrera porque sentía que encajaba conmigo desde hacía mucho tiempo. Siempre me habían gustado las asignaturas relacionadas con la programación y, además, crecí en un entorno en el que la informática estaba bastante presente. También valoré que se tratase de una carrera con muchas salidas profesionales, pero lo que más peso tuvo fue la sensación de que estaba eligiendo algo que verdaderamente me interesaba. Mi objetivo al empezar era disfrutar de la experiencia universitaria, aprender de verdad y encontrar un camino de vida con el que pudiera sentirme realizado tanto a nivel personal como profesional.

Mi recorrido en la carrera ha estado lleno de buenos momentos, aunque también ha sido exigente y duro en muchos puntos. Ha habido asignaturas especialmente complicadas, semanas de muchísima carga de trabajo y momentos de estrés en los que parecía que todo se acumulaba a la vez. Aun así, nunca me he planteado abandonar. Siempre he tenido claro que estaba donde quería estar, aunque a veces el camino resultara difícil. Mirando atrás, creo que una de las cosas que más me ha ayudado ha sido afrontar la carrera con constancia y con la idea de dar lo mejor de mí cuando realmente tocaba hacerlo. También me llevo una satisfacción especial de aquellas asignaturas en las que el esfuerzo continuo tenía un retorno visible, ya fuera porque entendía bien la materia, porque disfrutaba trabajando en ella o porque el profesor valoraba esa implicación. En ese sentido, he comprobado algo importante: muchas veces no solo marca la diferencia la asignatura en sí, sino la manera en que un profesor sabe transmitirla.

Durante estos años también he cambiado mucho personalmente. Una carrera como Ingeniería Informática te enseña bastante más que contenidos técnicos. Te obliga a organizarte, a trabajar con orden, a soportar la frustración cuando algo no sale, a volver a intentarlo, a pensar con calma en momentos de presión y a mantener la constancia incluso cuando el cansancio pesa. Todo eso hace que uno madure. Siento que salgo de la universidad

con más criterio, más capacidad para analizar problemas y también con una forma de pensar más crítica y más realista. Además, creo que en la UFV esa formación no se ha quedado solo en lo técnico. La universidad me ha ayudado también a entender que la dimensión humana, ética y personal del trabajo importa de verdad. No se trata solo de ser competente, sino de intentar ser un profesional completo.

En ese camino han sido muy importantes mis amigos de la carrera. Compartir con ellos las dificultades, el esfuerzo, los momentos de agobio y también los buenos ratos ha sido una parte fundamental de esta etapa. Cuando varias personas están pasando por experiencias parecidas, se entienden de una forma especial, y ese apoyo mutuo ha hecho mucho más llevaderos los años de universidad. También me han marcado especialmente aquellos profesores que transmitían auténtica ilusión por lo que enseñaban, porque han sido ellos los que muchas veces han conseguido que el aprendizaje no se quedara en aprobar una asignatura, sino en descubrir un interés real por lo que estaba estudiando.

En este contexto, la elección del PFG no ha sido casual. Este trabajo surge como una síntesis bastante natural de lo vivido durante la carrera: une el aprendizaje técnico, la capacidad de enfrentarse a problemas complejos y la necesidad de trabajar con constancia, orden y paciencia. Más que ser solo un proyecto final, siento que representa bastante bien la manera en la que he vivido estos años en la universidad: como un proceso de esfuerzo, aprendizaje, adaptación y crecimiento personal. Por eso, entiendo este PFG como la culminación de mi camino universitario, no solo porque cierre una etapa académica, sino porque también recoge buena parte de todo lo que esta etapa me ha enseñado.

7.2. VINCULACIÓN CON MI FUTURO PROFESIONAL

La realización de este Proyecto de Fin de Grado ha tenido para mí un sentido muy claro en relación con mi futuro profesional, porque conecta de forma directa con el ámbito al que quiero dedicarme. A lo largo de la carrera fui descubriendo poco a poco qué áreas me interesaban más, pero con el paso del tiempo esa dirección se ha ido concretando hasta quedar bastante definida. Si en un primer momento me llamaban la atención distintas ramas de la informática, con las asignaturas relacionadas con bases de datos, inteligencia artificial y análisis de datos, empecé a ver con claridad que ese era el camino en el que más encajaba. Este proyecto ha reforzado todavía más esa idea, porque me ha permitido trabajar precisamente en un entorno donde se cruzan el tratamiento de datos, el desarrollo de modelos y la creación de soluciones con una finalidad real.

Creo que este proyecto dice de mí que me motivan los retos complejos, especialmente cuando tienen una aplicación práctica y cuando el resultado final puede ser útil más allá del propio ejercicio académico. Siempre me ha interesado más construir algo nuevo, o dar forma a una solución con sentido, que limitarme a reproducir algo ya hecho. Por eso este PFG encaja con lo que busco también a nivel profesional, no solo quiero programar, sino participar en proyectos que aporten valor, que requieran pensar de verdad y que obliguen a conectar distintas piezas hasta encontrar una solución sólida. En ese sentido, el trabajo realizado

refleja bastante bien cómo entiendo mi futuro laboral, como un espacio en el que combinar desarrollo, análisis, resolución de problemas y capacidad de adaptación.

El proyecto también me ha servido para descubrir cosas sobre mí mismo. Una de las más importantes es que disfruto especialmente con la parte de construcción y desarrollo de soluciones, incluso cuando eso supone atravesar momentos de frustración o de bloqueo. Programar muchas veces exige paciencia, insistencia y tolerancia al error, y este PFG me ha confirmado que, aunque ese proceso puede ser duro, la satisfacción de resolver un problema compensa con creces el esfuerzo previo. Además, me ha hecho ver que me siento cómodo enfrentándome a proyectos largos y complejos, siempre que pueda organizarlos paso a paso y avanzar con un criterio claro. También me ha ayudado a confirmar que me veo más en un perfil orientado al desarrollo y a la aplicación práctica que en una línea puramente investigadora o centrada en la redacción académica. Es decir, me interesa investigar en la medida en que me permite construir algo útil, pero donde más cómodo me siento es en la parte de desarrollar, probar, corregir y llevar una idea a una solución real.

El propio trabajo del PFG me ha confirmado también la importancia de tratar los datos con rigor. Tanto en el análisis de datos como en inteligencia artificial, una pequeña alteración puede cambiar el significado de la información y afectar a todo el resultado posterior. Esa exigencia me ha hecho ser más consciente de la responsabilidad que conlleva trabajar en este ámbito. No se trata solo de que algo funcione, sino de que esté bien planteado, sea consistente y tenga sentido desde el origen de los datos hasta la solución final. Esa forma de trabajar, más exigente y cuidadosa, ha reforzado mi interés por este sector, porque me atrae precisamente ese nivel de precisión y de responsabilidad que requiere.

De cara al futuro, siento que este proyecto supone un punto de inflexión en mi vida. Lo más inmediato es que, he firmado un precontrato para que 2 días tras la exposición del PFG, entro como el primer desarrollador de IA y Data en la historia de la empresa en la que llevo 1 año de prácticas. El segundo cambio tiene que ver con una iniciativa más emprendedora, ya que he empezado también un proyecto con un compañero para ofrecer soluciones de inteligencia artificial a empresas. En ese sentido, el PFG no solo me ha servido como cierre de etapa universitaria, sino también como una carta de presentación de cara al futuro, pues demuestra que puedo desenvolverme en un proyecto complejo, que soy capaz de sostener un trabajo largo en el tiempo y que puedo moverme en un ámbito que combina datos, inteligencia artificial y aplicación real.

En definitiva, este PFG está claramente vinculado con el tipo de futuro profesional que deseo construir. Me ha permitido confirmar hacia dónde quiero orientar mi carrera, descubrir mejor en qué tipo de trabajo encajo y tomar conciencia de qué es lo que más valoro dentro de la informática: crear soluciones útiles, trabajar con datos de forma rigurosa y enfrentarme a retos que exijan pensar, construir y mejorar de forma continua. Por eso, más que un simple trabajo final, siento que este proyecto representa un puente entre mi etapa universitaria y la vida profesional que quiero empezar a desarrollar a partir de ahora.

8. CONCLUSIONES

El desarrollo de este proyecto ha permitido cumplir el objetivo principal planteado de ampliar el análisis de señales neuronales hacia el tratamiento de datos de fMRI, representando la conectividad cerebral mediante grafos y utilizando dichas representaciones como entrada para modelos de Deep Learning. A lo largo del trabajo se ha construido un flujo completo que abarca desde la carga y preprocesamiento de fMRIs hasta la generación de matrices de conectividad, grafos cerebrales, visualizaciones y resultados experimentales mediante una GNN.

Una de las principales conclusiones es que la representación mediante grafos resulta viable para estructurar la información contenida en fMRIs. El uso de atlas cerebrales permite transformar una imagen funcional 4D en una red de regiones conectadas, lo que facilita estudiar la conectividad cerebral desde una perspectiva diferente a la imagen tradicional. Además, la integración de esta funcionalidad dentro de la librería demuestra que el enfoque puede reutilizarse y extenderse a nuevos conjuntos de datos o configuraciones.

Desde el punto de vista experimental, la GNN entrenada sobre los grafos generados obtuvo resultados superiores al azar, especialmente en la detección de pacientes. No obstante, el modelo presentó limitaciones importantes, principalmente una menor capacidad para clasificar correctamente sujetos control. Por tanto, los resultados permiten validar la prueba de concepto desde un punto de vista técnico, pero no deben interpretarse como una validación clínica del sistema. El proyecto demuestra que el pipeline funciona y que las representaciones generadas contienen información útil, aunque todavía sería necesario mejorar la robustez, aumentar el tamaño muestral y reducir el efecto de la heterogeneidad entre datasets.

Como líneas futuras, sería recomendable incorporar más sujetos, aplicar técnicas de armonización entre datasets, comparar la GNN con modelos clásicos, evaluar otros atlas y medidas de conectividad, estudiar grafos ponderados y profundizar en la interpretación de las métricas estructurales de los grafos.

En conjunto, el proyecto ha supuesto un reto técnico considerable, tanto por la complejidad de los datos de neuroimagen como por la integración de distintas disciplinas: procesamiento de imagen médica, conectividad cerebral, teoría de grafos y aprendizaje profundo. A pesar de las dificultades, se ha conseguido completar una prueba de concepto ambiciosa y funcional, lo que supone una base sólida para futuras ampliaciones.

9. OTROS MÉRITOS DEL PROYECTO

Además de los objetivos principales, el proyecto presenta varios méritos adicionales. En primer lugar, se ha desarrollado una solución basada en software libre y datasets abiertos, lo que favorece la reproducibilidad y la transparencia del trabajo. El uso de repositorios públicos y herramientas abiertas permite que el sistema pueda ser revisado, reutilizado y ampliado en el futuro.

Otro mérito relevante es la integración de varias áreas de conocimiento en un único flujo funcional. El proyecto no se limita al entrenamiento de un modelo, sino que conecta neuroimagen, preprocesamiento de fMRI, extracción de conectividad funcional, construcción de grafos, visualización y clasificación mediante redes neuronales. Esta integración aporta valor añadido, ya que permite estudiar el problema de forma completa desde los datos originales hasta el resultado final.

También destaca la disponibilidad de ejemplos, notebooks y scripts que facilitan la reproducción de los experimentos. La librería no queda únicamente como código interno, sino que incluye ejemplos de uso y salidas intermedias que permiten entender mejor el proceso. Esto mejora la utilidad del proyecto y facilita que pueda servir como punto de partida para otros trabajos relacionados con análisis de neuroimagen mediante grafos.

Finalmente, debe destacarse el esfuerzo realizado para completar un proyecto técnicamente exigente en un periodo reducido. Durante varios meses se ha trabajado de forma continuada para resolver problemas de carga de datos, preprocesamiento, visualización, transformación a grafos, entrenamiento y evaluación. Haber conseguido cerrar un flujo completo y funcional, pese a la dificultad del objetivo planteado, constituye en sí mismo un mérito importante del proyecto.

10. BIBLIOGRAFÍA

- [1] Bitbrain, «Colocación de electrodos EEG en un Layout Fijo vs. Variable», <https://www.bitbrain.com/es/blog/colocacion-electrodos-eeeg>.
- [2] Imagen 1 Gemini, «conversación exclusiva para generar la imagen 1», <https://gemini.google.com/app/4007fd699c3f3a4a>.
- [3] ufvceiec, «EEGGraph», <https://github.com/ufvceiec/EEGRAPH>.
- [4] A. Lorenzo Martín, «Análisis del estudio de la migraña con resonancia magnética mediante medidas avanzadas y técnicas de inteligencia artificial», <https://uvadoc.uva.es/handle/10324/62127>. [En línea]. Disponible en: <https://uvadoc.uva.es/handle/10324/62127>
- [5] Tsuyoshi Tajima *et al.*, «Artificial intelligence using neural network architecture for radiology (AINNAR): classification of MR imaging sequences», <https://link.springer.com/article/10.1007/s11604-018-0779-3>.
- [6] Frankie K. F. Mo *et al.*, «Convolutional neural network for discriminating nasopharyngeal carcinoma and benign hyperplasia on MRI», <https://link.springer.com/article/10.1007/s00330-020-07451-y>.
- [7] Shenbagarajan Anantharajan, Shenbagalakshmi Gunasekaran, Thavasi Subramanian, y Venkatesh R, «MRI brain tumor detection using deep learning and machine learning approaches», <https://www.sciencedirect.com/science/article/pii/S2665917424000023>.
- [8] Xiaohong Liang MD, Kaiqiang Tang MD, Xiaoi Ke MS, Jian Jiang MD, Shenglin Li MD, y Caiqiang Xue MD, «Development of an MRI-Based Comprehensive Model Fusing Clinical, Radiomics and Deep Learning Models for Preoperative Histological Stratification in Intracranial Solitary Fibrous Tumor», <https://onlinelibrary.wiley.com/doi/abs/10.1002/jmri.29098>.
- [9] Rodrigo Santa Cruz, Leo Lebrat, Pierrick Bourgeat, Clinton Fookes, Jurgen Fripp, y Olivier Salvado, «DeepCSR: A 3D Deep Learning Approach for Cortical Surface Reconstruction», https://openaccess.thecvf.com/content/WACV2021/html/Santa_Cruz_DeepCSR_A_3D_Deep_Learning_Approach_for_Cortical_Surface_Reconstruction_WACV_2021_paper.html.
- [10] Vicente Grau, Abhirup Banerjee, y Marcel Beetz, «Point2Mesh-Net: Combining Point Cloud and Mesh-Based Deep Learning for Cardiac Shape Reconstruction», https://link.springer.com/chapter/10.1007/978-3-031-23443-9_26.

- [11] Shu-Hang Ng *et al.*, «Fully automated segmentation and radiomics feature extraction of hypopharyngeal cancer on MRI using deep learning», <https://link.springer.com/article/10.1007/s00330-023-09827-2>.
- [12] Alfonso Bueno-Orovio, Abhirup Banerjee, y Emma McMillian, «From 2D to 3D, Deep Learning-based Shape Reconstruction in Magnetic Resonance Imaging: A Review», <https://arxiv.org/abs/2510.01296>.
- [13] David Ahméd-Aristizabal, Mohammad Ali Armin, Simon Denman, Clinton Fookes, y Lars Petersson, «Graph-Based Deep Learning for Medical Diagnosis and Analysis: Past, Present and Future», <https://www.mdpi.com/1424-8220/21/14/4758>.
- [14] RABIA UYAR, Gürçan Yavuz, Pinar Ozen, y EMİNE DENİZ ÖZ, «Hybrid Artificial Intelligence Models: Methods, Optimization, and Applications», https://www.researchgate.net/publication/399187218_Hybrid_Artificial_Intelligence_Models_Methods_Optimization_and_Applications#page=46.
- [15] Kini Chen, Mohammad Torabi, A. Y. Y. Jie Jian, y Jean-Baptiste Poline, «Deep Learning for Cognitive Task Presence Prediction from Dynamic Functional Connectivity», <https://www.biorxiv.org/content/10.1101/2025.11.14.688561v1.abstract>.
- [16] L. PASA, «Dynamic Functional Connectome Fingerprinting with Deep Learning for Temporal Graphs», <https://thesis.unipd.it/handle/20.500.12608/84784>.
- [17] Microsoft, «Visual Studio Code», <https://code.visualstudio.com/>.
- [18] Salesforce, «Slack», <https://slack.com/intl/es-es>.
- [19] BarD Software s.r.o, «GanttProject», https://www.ganttproject.biz/#google_vignette.
- [20] Guido van Rossum, «Python», <https://www.python.org/>.
- [21] Facebook AI Research (FAIR), «PyTorch», <https://pytorch.org/>.
- [22] Matthias Fey y Jan E. Lenssen, «PyTorch Geometric (PyT)», <https://pytorch-geometric.readthedocs.io/en/latest/>.
- [23] «Mendeley Cite», <https://www.mendeley.com/reference-management/mendeley-cite>.
- [24] «OpenNeuro», <https://openneuro.org/>.
- [25] R. National Institute for Research and Development in Informatics, Department of Neurobiology, Beijing Institute of Geriatrics, Xuanwu Hospital, y C. Capital Medical University; Parkinson Disease Centre of Beijing Institute for Brain Disorders, «Parkinson's Disease Datasets - Neurocon», https://fcon_1000.projects.nitrc.org/indi/retro/parkinsons.html.
- [26] «The Brain Imaging Data Structure», <https://bids.neuroimaging.io/index.html>.
- [27] «Atlas Repositorio», <https://github.com/brainspaces>.

- [28] Alberto Nogales, Ana M. Maitín, y Álvaro J. García-Tejedor, «Best Practices to Train Accurate Deep Learning Models: A General Methodology», <https://thesai.org/Publications/ViewPaper?Volume=17&Issue=2&Code=ijacsa&SerialNo=6>.
- [29] «National Institute of Neurological Disorders and Strokes», <https://www.ninds.nih.gov/health-information/disorders/parkinsons-disease>.
- [30] «Parkinson's Foundation». Accedido: 3 de mayo de 2026. [En línea]. Disponible en: <https://www.parkinson.org/understanding-parkinsons/getting-diagnosed>
- [31] «Parkinson's UK», <https://www.parkinsons.org.uk/information/about-parkinsons/how-diagnosed>.
- [32] Marcelo Merello, Santiago Perez-Lloret, y Malco Rossi, «How much time is needed in clinical practice to reach a diagnosis of clinically established Parkinson's disease?», <https://www.sciencedirect.com/science/article/abs/pii/S1353802021003710>.
- [33] Tom Hähnel, Tamara Raschka, Holger Fröhlich, y Jochen Klucken, «Predictive modeling to uncover Parkinson's disease characteristics that delay diagnosis», <https://www.nature.com/articles/s41531-025-00923-2>.
- [34] Marzieh Keshtkarjahromi, Danielle S Abraham, y Ann L Gruber-Baldini, «Confirming Parkinson Disease Diagnosis: Patterns of Diagnostic Changes by Movement Disorder Specialists», <https://pmc.ncbi.nlm.nih.gov/articles/PMC9110256/>.
- [35] Giovanni Rizzo, Massimiliano Copetti, Simona Arcuti, y Davide Martino, «Accuracy of clinical diagnosis of Parkinson disease: A systematic review and meta-analysis», <https://pubmed.ncbi.nlm.nih.gov/26764028/>.
- [36] ACM, «Código de Ética y Conducta Profesional de la ACM», <https://www.acm.org/about-acm/code-of-ethics-in-spanish>.
- [37] Unión Europea, «Reglamento General de Protección de Datos», <https://eur-lex.europa.eu/ES/legal-content/summary/general-data-protection-regulation-gdpr.html>.
- [38] Agencia Estatal Boletín Oficial del Estado, «Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales.», <https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673>.
- [39] Agencia Estatal Boletín Oficial del Estado, «Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial y por el que se modifican los Reglamentos (CE) n° 300/2008, (UE) n° 167/2013, (UE) n° 168/2013, (UE) 2018/858, (UE) 2018/1139 y (UE) 2019/2144 y las Directivas 2014/90/UE, (UE) 2016/797 y (UE) 2020/1828 (Reglamento de Inteligencia Artificial).», <https://www.boe.es/buscar/doc.php?id=DOUE-L-2024-81079>.
- [40] Gemini, «Chat con Gemini para Estado del Arte», <https://gemini.google.com/share/1fd1db8d6680>.

[41] «fMRIPrep», <https://fmriprep.org/en/stable/outputs.html>.

ANEXO A: DETALLE DE DATASETS UTILIZADOS

NEUROCON

Una de las fuentes empleadas fue Neurocon, utilizado como origen adicional de sujetos con Parkinson y sujetos sanos. Según la documentación consultada, este conjunto incluía pacientes con enfermedad de Parkinson y controles sanos de edad comparable, todos ellos adquiridos mediante resting-state fMRI, lo que lo hacía especialmente útil para una tarea de clasificación binaria entre presencia y ausencia de enfermedad. Metodológicamente, este dataset resultó ventajoso porque ya se encontraba separado entre clases clínicas, lo que facilitó su incorporación inicial al flujo de trabajo.

OPENNEURO

10.1.1. OpenNeuro ds005892

También se utilizó el dataset OpenNeuro ds005892, organizado siguiendo el estándar BIDS. Este conjunto incluía controles sanos, pacientes con Parkinson y cognición normal, y pacientes con Parkinson con deterioro cognitivo leve. Para este trabajo, ambos subgrupos clínicos de Parkinson se agruparon como “patient”, manteniéndose la clasificación binaria deseada para poder centrarse en la detección de enfermedad y no en la clasificación de la patología.

10.1.2. OpenNeuro ds004718

Como fuente complementaria para la categoría de “control” se incorporó OpenNeuro ds004718, también estructurado en formato BIDS. Aunque el objetivo original de este dataset no era el estudio de Parkinson, sí aportaba sujetos sanos de edad avanzada con adquisiciones de fMRI, lo que lo convertía en un recurso útil para reforzar la clase control y reducir parcialmente el sesgo que aparecería al comparar sujetos de la clase “patient” con sujetos excesivamente jóvenes de la clase “control”. Siguiendo por tanto un criterio de equilibrio clínico razonable.

10.1.3. OpenNeuro ds004392

Por último, se utilizó OpenNeuro ds004392, también basado en resting-state fMRI, que contenía exclusivamente sujetos diagnosticados con enfermedad de Parkinson. Dado que este conjunto no incluía controles sanos, todos sus participantes se incorporaron directamente a la clase “patient”. Esta decisión permitió reforzar dicha clase del conjunto

total, aunque también introdujo una mayor heterogeneidad clínica interna, ya que dentro de dicha clase convivían sujetos con distintos perfiles cognitivos.

10.2. REPARTO DE DATOS

A continuación, se muestra el reparto de los datos provenientes de cada dataset.

clase	dataset_origen	control	patient	total
0	Neurocon	14	25	39
1	OpenNeuro ds004392	0	55	55
2	OpenNeuro ds005892	22	32	54
3	OpenNeuro ds004718	47	0	47
		83	112	195

Tabla 17: Muestras en bruto por dataset. Fuente: Elaboración propia.

clase	dataset_origen	control	patient	total
0	Neurocon	14	25	39
1	OpenNeuro ds004392	0	55	55
2	OpenNeuro ds005892	13	25	38
3	OpenNeuro ds004718	46	0	46
		73	105	178

Tabla 18: Muestras tras filtrado de 116x116. Fuente: Elaboración propia.

ANEXO B: PLAN DE TRABAJO

En este apartado de los anexos se incluyen las tablas y figuras relativas a los planes de trabajo inicial y final mostrando la jerarquía de paquetes de trabajo, actividades y tareas, y ampliando la información para cada paquete de trabajo. A demás, se incluyen imágenes del Gantt para mostrar la jerarquía de manera más visual.

PLAN DE TRABAJO INICIAL

Esta es la estructura general, de cómo se estructuró en un inicio el plan de trabajo, incluyendo paquetes de trabajo, actividades, tareas y recursos para cada tarea.

PT	ACT	TR	Recursos
PT1	ACT1.1	TR1.1.1 Revisión de la arquitectura general de EEGraph	R1, R2
PT1	ACT1.1	TR1.1.2 Análisis del flujo de datos y módulos reutilizables	R1, R2
PT1	ACT1.1	TR1.1.3 Estudio de ejemplos y pruebas de ejecución	R1, R2
PT1	ACT1.2	TR1.2.1 Identificación de limitaciones de EEGraph respecto a fMRI	R1
PT1	ACT1.2	TR1.2.2 Definición preliminar del alcance técnico del TFG	R1, R2
PT1	ACT1.2	TR1.2.3 Planificación inicial del proyecto	R1, R3
PT2	ACT2.1	TR2.1.1 Investigación sobre modelado de fMRI como grafo	R1
PT2	ACT2.1	TR2.1.2 Estudio de atlas, ROIs y conectividad funcional	R1
PT2	ACT2.1	TR2.1.3 Selección del enfoque metodológico más adecuado	R1, R2
PT2	ACT2.2	TR2.2.1 Redacción del estado del arte	R3
PT2	ACT2.2	TR2.2.2 Redacción de objetivos y objetivos específicos	R3
PT2	ACT2.2	TR2.2.3 Redacción de métodos de validación	R3
PT3	ACT3.1	TR3.1.1 Entrada	R2
PT3	ACT3.1	TR3.1.2 Normalización de formatos	R2
PT3	ACT3.1	TR3.1.3 Preprocesado	R2
PT3	ACT3.1	TR3.1.4 Denoising	R2
PT3	ACT3.1	TR3.1.5 Mapeo con atlas	R2

PT3	ACT3.1	TR3.1.6 Series temporales por ROI	R2
PT3	ACT3.1	TR3.1.7 Conectividad funcional	R2
PT3	ACT3.1	TR3.1.8 Construcción del grafo	R2
PT3	ACT3.1	TR3.1.9 Validación y tests internos	R2
PT4	ACT4.1	TR4.1.1 Preparación y entrega de la librería para validación externa	R2
PT4	ACT4.1	TR4.1.2 Validación funcional por Iván Barcia	R4
PT4	ACT4.1	TR4.1.3 Validación funcional por Alberto Nogales	R5
PT4	ACT4.1	TR4.1.4 Recogida de incidencias, feedback y ajustes menores	R2
PT5	ACT5.1	TR5.1.1 Selección y organización del dataset de fMRI	R1, R2
PT5	ACT5.1	TR5.1.2 Transformación del dataset a grafos con la librería	R2
PT5	ACT5.2	TR5.2.1 Definición del pipeline y particiones de entrenamiento, validación y test	R2
PT5	ACT5.3	TR5.3.1 Implementación del código del modelo GCNN	R2
PT5	ACT5.3	TR5.3.2 Ajuste de hiperparámetros y configuración experimental	R2
PT5	ACT5.4	TR5.4.1 Entrenamiento del modelo	R2
PT5	ACT5.4	TR5.4.2 Validación del modelo	R2
PT6	ACT6.1	TR6.1.1 Redacción de apartados pendientes	R3
PT6	ACT6.1	TR6.1.2 Documentación, revisión y reescritura de métodos y plan de trabajo	R3
PT6	ACT6.2	TR6.2.1 Redacción de resultados, discusión y conclusiones	R3
PT6	ACT6.2	TR6.2.2 Integración de resultados de la GCNN	R3
PT6	ACT6.3	TR6.3.1 Revisión formal, correcciones y homogeneización del documento	R3

Tabla 19: Jerarquía de los Paquetes de trabajo (PT) del plan inicial. Fuente: Elaboración propia.

PT1

En este punto se detallan las actividades y tareas relativas al paquete de trabajo PT1 del Plan de Trabajo Inicial

Código	Descripción	Qué hace	Qué incluye
PT1	Estudio preliminar del problema y comprensión de EEGraph	Analiza la librería base y delimita técnicamente el TFG	ACT1.1 ACT1.2
ACTIVIDADES			
ACT1.1	Revisión de arquitectura y flujo de EEGraph	Estudia la estructura y funcionamiento interno de la librería	TR1.1.1, TR1.1.2, TR1.1.3
ACT1.2	Delimitación técnica del TFG	Define límites, alcance y planificación inicial del trabajo	TR1.2.1, TR1.2.2, TR1.2.3
TAREAS			
TR1.1.1	Revisión de la arquitectura general de EEGraph	Estudia la estructura base de la librería	
TR1.1.2	Análisis del flujo de datos y módulos reutilizables	Analiza el flujo interno y los componentes aprovechables	
TR1.1.3	Estudio de ejemplos y pruebas de ejecución	Comprueba el funcionamiento práctico de la librería	
TR1.2.1	Identificación de limitaciones de EEGraph respecto a fMRI	Detecta las carencias de la librería para esta modalidad	
TR1.2.2	Definición preliminar del alcance técnico del TFG	Delimita técnicamente lo que se desarrollará	
TR1.2.3	Planificación inicial del proyecto	Fija una primera organización del trabajo	

Tabla 20: Detalle del paquete de trabajo PT1 del Plan de Trabajo Inicial. Fuente: Elaboración propia.




Figura 9. Plan de Trabajo Inicial - PT1. Fuente: Elaboración propia

PT2

En este punto se detallan las actividades y tareas relativas al paquete de trabajo PT2 del Plan de Trabajo Inicial

Código	Descripción	Qué hace	Qué incluye
PT2	Investigación metodológica y documentación base	Desarrolla la investigación metodológica sobre fMRI y la documentación inicial	ACT2.1
ACTIVIDADES			
ACT2.1	Investigación metodológica sobre fMRI y grafos	Analiza la base metodológica del proyecto	TR2.1.1, TR2.1.2, TR2.1.3
ACT2.2	Documentación, revisión y reescritura inicial	Redacta el estado del arte, objetivos y métodos de validación	TR2.2.1, TR2.2.2, TR2.2.3
TAREAS			
TR2.1.1	Investigación sobre modelado de fMRI como grafo	Revisa cómo transformar fMRI a grafos	
TR2.1.2	Estudio de atlas, ROIs y conectividad funcional	Analiza los elementos metodológicos clave	
TR2.1.3	Selección del enfoque metodológico más adecuado	Escoge el enfoque técnico a seguir	
TR2.2.1	Redacción del estado del arte	Redacta el marco teórico inicial	
TR2.2.2	Redacción de objetivos y objetivos específicos	Formula las metas del trabajo	
TR2.2.3	Redacción de métodos de validación	Define cómo se evaluará el proyecto	

Tabla 21: Detalle del paquete de trabajo PT2 del Plan de Trabajo Inicial. Fuente: Elaboración propia.




Figura 10. Plan de Trabajo Inicial - PT2. Fuente: Elaboración propia

PT3

En este punto se detallan las actividades y tareas relativas al paquete de trabajo PT3 del Plan de Trabajo Inicial

Código	Descripción	Qué hace	Qué incluye
PT3	Diseño, desarrollo e integración de la librería para fMRI	Implementa el flujo técnico de la librería desde la entrada hasta la validación interna	ACT3.1
ACTIVIDADES			
ACT3.1	Desarrollo del flujo de librería fMRI	Implementa el procesamiento completo de la librería	TR3.1.1, TR3.1.2, TR3.1.3, TR3.1.4, TR3.1.5, TR3.1.6, TR3.1.7, TR3.1.8, TR3.1.9
TAREAS			
TR3.1.1	Entrada	Implementa la fase de entrada de datos	
TR3.1.2	Normalización de formatos	Homogeneiza los formatos de entrada	
TR3.1.3	Preprocesado	Prepara los datos antes del análisis principal	
TR3.1.4	Denoising	Reduce ruido en la señal fMRI	
TR3.1.5	Mapeo con atlas	Relaciona la señal con regiones definidas por atlas	
TR3.1.6	Series temporales por ROI	Obtiene las series temporales regionales	
TR3.1.7	Conectividad funcional	Calcula relaciones entre regiones cerebrales	
TR3.1.8	Construcción del grafo	Genera la representación final en grafo	
TR3.1.9	Validación y tests internos	Comprueba internamente el funcionamiento de la librería	

Tabla 22: Detalle del paquete de trabajo PT1 del Plan de Trabajo Inicial. Fuente: Elaboración propia.




Figura 11. Plan de Trabajo Inicial - PT3. Fuente: Elaboración propia

PT4

En este punto se detallan las actividades y tareas relativas al paquete de trabajo PT4 del Plan de Trabajo Inicial

Código	Descripción	Qué hace	Qué incluye
PT4	Validación externa de la librería	Organiza y recoge la validación funcional externa	ACT4.1
ACTIVIDADES			
ACT4.1	Validación funcional externa	Coordina la entrega, validación y recogida de feedback externo	TR4.1.1, TR4.1.2, TR4.1.3, TR4.1.4
TAREAS			
TR4.1.1	Preparación y entrega de la librería para validación externa	Prepara la librería para revisión externa	
TR4.1.2	Validación funcional por Iván Barcia	Revisión externa funcional de la librería	
TR4.1.3	Validación funcional por Alberto Nogales	Segunda revisión externa funcional de la librería	
TR4.1.4	Recogida de incidencias, feedback y ajustes menores	Recoge observaciones y aplica ajustes	

Tabla 23: Detalle del paquete de trabajo PT4 del Plan de Trabajo Inicial. Fuente: Elaboración propia.




Figura 12. Plan de Trabajo Inicial - PT4. Fuente: Elaboración propia

PT5

En este punto se detallan las actividades y tareas relativas al paquete de trabajo PT5 del Plan de Trabajo Inicial

Código	Descripción	Qué hace	Qué incluye
PT5	Desarrollo de la prueba de concepto con GCNN	Prepara el dataset, define el pipeline experimental y desarrolla el modelo	ACT5.1 ACT5.2 ACT5.3 ACT5.4
ACTIVIDADES			
ACT5.1	Preparación del dataset y generación de grafos	Organiza el dataset y lo transforma a grafos	TR5.1.1, TR5.1.2
ACT5.2	Preparación del pipeline experimental	Define la estructura experimental y las particiones	TR5.2.1
ACT5.3	Desarrollo del modelo GCNN	Implementa el modelo y ajusta su configuración	TR5.3.1, TR5.3.2
ACT5.4	Entrenamiento, validación y test	Ejecuta la parte experimental del modelo	TR5.4.1, TR5.4.2
TAREAS			
TR5.1.1	Selección y organización del dataset de fMRI	Prepara el conjunto de datos para la prueba de concepto	
TR5.1.2	Transformación del dataset a grafos con la librería	Convierte el dataset a grafos	
TR5.2.1	Definición del pipeline y particiones de entrenamiento, validación y test	Estructura el experimento y divide los datos	
TR5.3.1	Implementación del código del modelo GCNN	Desarrolla el modelo de red neuronal	
TR5.3.2	Ajuste de hiperparámetros y configuración experimental	Ajusta la configuración del experimento	
TR5.4.1	Entrenamiento del modelo	Entrena la GCNN	
TR5.4.2	Validación del modelo	Evalúa el rendimiento sobre validación	

Tabla 24: Detalle del paquete de trabajo PT5 del Plan de Trabajo Inicial. Fuente: Elaboración propia.




Figura 13. Plan de Trabajo Inicial - PT5. Fuente: Elaboración propia

PT6

En este punto se detallan las actividades y tareas relativas al paquete de trabajo PT6 del Plan de Trabajo Inicial

Código	Descripción	Qué hace	Qué incluye
PT6	Documentación final, revisión y cierre del proyecto	Completa la memoria y prepara el cierre documental	ACT6.1 ACT6.2 ACT6.3
ACTIVIDADES			
ACT6.1	Redacción y actualización de documentación	Avanza en la redacción de apartados pendientes	TR6.1.1, TR6.1.2
ACT6.2	Integración de resultados y cierre de memoria	Integra resultados y redacta el cierre de la memoria	TR6.2.1, TR6.2.2
ACT6.3	Revisión final y preparación de la versión definitiva	Revisa y homogeneiza la versión final	TR6.3.1
TAREAS			
TR6.1.1	Redacción de apartados pendientes	Completa apartados todavía no cerrados	
TR6.1.2	Documentación, revisión y reescritura de métodos y plan de trabajo	Revisa y reescribe estos apartados	
TR6.2.1	Redacción de resultados, discusión y conclusiones	Redacta el cierre analítico del trabajo	
TR6.2.2	Integración de resultados de la GCNN	Incorpora los resultados experimentales	
TR6.3.1	Revisión formal, correcciones y homogeneización del documento	Da coherencia final a la memoria	

Tabla 25: Detalle del paquete de trabajo PT5 del Plan de Trabajo Inicial. Fuente: Elaboración propia.




Figura 14. Plan de Trabajo Inicial - PT6. Fuente: Elaboración propia

PLAN DE TRABAJO FINAL

Los cambios en la estructura del Plan de Trabajo Final respecto al Plan de Trabajo Inicial, son los siguientes. La actividad ACT2.2, respectiva al paquete de trabajo PT2, incluye una nueva tarea TR2.2.4 – Documentación, revisión y reescritura de la parte inicial. La actividad ACT5.4, respectiva al paquete de trabajo PT5, incluye una nueva tarea TR5.4.3 – Evaluación final sobre test y análisis inicial de resultados. Por último, La actividad ACT6.3, respectiva al paquete de trabajo PT6, incluye una nueva tarea TR6.3.2 – Preparación de la versión final del TFG. Esto implica que el plan ahora pasa a tener 40 tareas en lugar de 37.

PT1




Figura 15. Plan de Trabajo Final - PT1. Fuente: Elaboración propia

PT2



Figura 16. Plan de Trabajo Final - PT2. Fuente: Elaboración propia

PT3




Figura 17. Plan de Trabajo Final - PT3. Fuente: Elaboración propia

PT4




Figura 18. Plan de Trabajo Final - PT4. Fuente: Elaboración propia

PT5




Figura 19. Plan de Trabajo Final - PT5. Fuente: Elaboración propia

PT6




Figura 20. Plan de Trabajo Final - PT6. Fuente: Elaboración propia

ANEXO C: REGISTRO DE RIESGOS

Se muestra a continuación la tabla de Registro de Riesgos mencionada en el apartado 6.5 de este documento.

Riesgo	Descripción	Probabilidad	Impacto	Acción/ Medida / Solución
R1	Uso de datos cerebrales sensibles sin suficiente cautela, incluyendo posibles problemas de privacidad o reutilización inadecuada de metadatos.	Media	Alto	Utilizar únicamente datasets públicos o adecuadamente anonimizados, revisar la documentación de uso de cada conjunto de datos, evitar almacenar información identificativa innecesaria y aplicar el principio de minimización de datos.
R2	Interpretación indebida del sistema como herramienta clínica o de diagnóstico automático.	Media	Alto	Dejar explícito en la memoria y en la documentación de la librería que el desarrollo tiene fines de investigación y apoyo al análisis, y que no sustituye el criterio de profesionales sanitarios ni realiza diagnósticos médicos por sí solo.
R3	Sesgo o falta de generalización de los resultados debido al uso de datasets limitados, heterogéneos o procedentes de distintas fuentes.	Alta	Alto	Documentar claramente el origen de los datos, reconocer las limitaciones del conjunto utilizado y evitar afirmaciones generales que excedan el alcance real de los experimentos realizados.
R4	Dependencia de los resultados respecto al preprocesado aplicado, al atlas seleccionado o a decisiones técnicas previas.	Alta	Alto	Explicar de forma transparente el flujo de procesamiento seguido, justificar los atlas soportados y reconocer expresamente que los resultados pueden variar en función de estas decisiones metodológicas.

R5	Errores en la transformación de fMRI a grafos, por ejemplo por desalineaciones anatómicas, asignación incorrecta de regiones o construcción defectuosa de la conectividad.	Media	Alto	Validar visual y técnicamente la correspondencia anatómica de los nodos, revisar la coherencia espacial de los grafos generados y contrastar los resultados con criterios anatómicos razonables.
R6	Sobreinterpretación de los resultados del modelo de IA, atribuyendo significado clínico o científico a patrones que no han sido suficientemente validados.	Media	Alto	Presentar los resultados con prudencia, acompañarlos de sus limitaciones y evitar asociar directamente rendimiento computacional con utilidad clínica real.
R7	Falta de reproducibilidad si no quedan bien documentados los datasets, atlas, parámetros y pasos de procesamiento utilizados.	Media	Medio	Mantener una documentación clara del flujo de trabajo, de los recursos empleados y de las decisiones técnicas adoptadas, de modo que otros usuarios puedan reproducir razonablemente el proceso.
R8	Uso incorrecto de la librería por parte de terceros que desconozcan sus límites o la apliquen fuera del contexto para el que fue diseñada.	Media	Medio	Incluir documentación de uso, advertencias sobre el alcance del sistema y una explicación clara de qué entradas admite, qué salidas produce y qué interpretación puede darse a esas salidas.
R9	Consumo computacional elevado derivado del procesamiento de neuroimagen y del entrenamiento de modelos de Deep Learning.	Baja	Medio	Evitar ejecuciones innecesarias, reutilizar resultados intermedios cuando sea posible y planificar los experimentos para reducir repeticiones sin valor añadido.
R10	Incumplimiento de condiciones de uso, licencias o atribución	Baja	Medio	Revisar y respetar las condiciones de uso de cada recurso externo, citar

	de datasets, atlas o recursos externos empleados en el proyecto.			adecuadamente los datasets, atlas y repositorios utilizados y dejar constancia de su procedencia en la memoria.
--	--	--	--	---

Tabla 26: Registro de Riesgos del proyecto. Fuente: Elaboración propia.

ANEXO D: PREPROCESAMIENTO PRUEBA DE CONCEPTO

LECTURA DEL ARCHIVO JSON SIDECAR Y EXTRACCIÓN DEL TR.

Cada archivo fMRI en formato NIFTI va acompañado, siguiendo el estándar BIDS, de un archivo JSON sidecar que contiene metadatos de adquisición. En este trabajo, ese archivo se utilizó principalmente para recuperar el TR (Repetition Time), un parámetro necesario para interpretar correctamente el eje temporal de la señal y para aplicar después el filtrado band-pass.

La referencia metodológica de esta parte procede del propio estándar BIDS, que define el uso de sidecars JSON para almacenar metadatos de las adquisiciones de resonancia magnética.

ESTANDARIZACIÓN GEOMÉTRICA ENTRE FUENTES.

Con el fin de reducir parte de la heterogeneidad entre datasets de distinto origen, antes de la transformación a grafo se aplicó una estandarización geométrica básica de las imágenes. Esta consistió en reorientar cada volumen a una orientación canónica común y en resamplearlo a un tamaño de voxel homogéneo. Conceptualmente, este paso no equivale a una normalización completa a un espacio estándar como MNI, pero sí ayuda a que las imágenes compartan una geometría más comparable antes de la parcelación anatómica.

La implementación técnica se basó en funciones de NiBabel, concretamente en las utilidades para llevar la imagen a una orientación canónica y para realizar resampling a una resolución espacial de salida definida.

NORMALIZACIÓN GLOBAL DE INTENSIDAD.

Tras la carga del volumen fMRI, se aplicó una normalización global de intensidad con el objetivo de homogeneizar la escala numérica de la señal entre muestras. En la práctica, este paso centra y reescala los valores de intensidad para reducir diferencias globales de magnitud entre sujetos o adquisiciones, de modo que el procesamiento posterior no quede dominado por cambios puramente de escala. Esta etapa no se tomó de una función específica de fMRIPrep, sino que se incorporó como una decisión metodológica propia de estabilización numérica previa a la transformación a grafo. La inspiración general viene de la necesidad de estandarizar la señal antes del análisis, aunque la implementación concreta es propia del estudio.

SPATIAL SMOOTHING.

Posteriormente, se aplicó un suavizado espacial mediante un filtro gaussiano. Conceptualmente, este preprocesamiento hace que cada voxel quede influido por sus vecinos espaciales, reduciendo ruido local y favoreciendo patrones regionales más estables. En un contexto de conectividad funcional, esto puede ayudar a obtener series temporales regionales menos sensibles a variaciones voxel a voxel demasiado finas o ruidosas. La referencia técnica de esta operación procede de SciPy, concretamente de la función `gaussian_filter`, que implementa el filtrado gaussiano multidimensional utilizado para este suavizado espacial.

DETECCIÓN DE OUTLIERS PARA CONTROL DE CALIDAD.

Además, se incorporó una detección automática de volúmenes atípicos con fines de control de calidad. Este paso no se utilizó como sustituto de confounds reales ni como una corrección fuerte del movimiento, sino como una herramienta para identificar volúmenes temporales potencialmente problemáticos y dejar trazabilidad de su presencia en cada muestra. La referencia metodológica general para justificar la importancia del control de calidad procede de fMRIPrep, que enfatiza la generación de informes visuales y la identificación de outliers como parte de una filosofía de procesamiento robusto y transparente. Sin embargo, la implementación concreta de esta detección en este trabajo es una heurística propia y no una reproducción literal del procedimiento interno de fMRIPrep.

REGRESIÓN DE CONFOUNDS REALES.

Cuando existen archivos auxiliares con confounds reales, el pipeline contempla la posibilidad de aplicar una regresión de confounds antes de calcular la conectividad. Conceptualmente, esta etapa sirve para eliminar de la señal parte de la variabilidad asociada a fuentes de ruido conocidas, como movimiento o señales no neuronales. La referencia metodológica de esta parte se tomó de los outputs de fMRIPrep, que documenta la generación de confounds como parámetros de movimiento, `white_matter`, `csf`, `global_signal`, `framewise_displacement`, `DVARS` y componentes de tipo CompCor. En este estudio, dicha regresión solo se considera válida cuando esos confounds proceden de archivos reales y no de outliers heurísticos generados internamente.

SCRUBBING.

De forma análoga, el scrubbing se planteó como una etapa condicional, aplicable únicamente cuando se dispone de métricas reales que permitan justificar la exclusión de volúmenes concretos, por ejemplo a partir de `framewise_displacement`, `DVARS` o regresores de outliers calculados externamente. Conceptualmente, el scrubbing busca eliminar volúmenes

temporales especialmente contaminados por movimiento u otras alteraciones, de manera que no influyan de forma desproporcionada en la conectividad final. La referencia de qué tipo de métricas son adecuadas para este fin también se tomó de la documentación de outputs de fMRIPrep, aunque en este trabajo no se considera correcto sustituirlas por outliers heurísticos generados por el propio script.

FILTRADO TEMPORAL BAND-PASS.

Finalmente, se aplicó un filtrado temporal band-pass a la señal. Su función es conservar únicamente el rango de frecuencias considerado de interés para la señal BOLD y atenuar tanto fluctuaciones muy lentas, asociadas por ejemplo a deriva del escáner, como fluctuaciones demasiado rápidas, más compatibles con ruido. Este paso es especialmente relevante en estudios de conectividad funcional, ya que se busca trabajar con una señal temporal más limpia antes de calcular relaciones entre regiones cerebrales. La implementación técnica se basó en SciPy Signal, utilizando un filtro Butterworth y aplicándolo en forma SOS con filtrado hacia delante y hacia atrás para evitar desfases temporales apreciables.

RELACIÓN CON LA LIBRERÍA FM RIPREP Y ALCANCE REAL DEL PREPROCESAMIENTO APLICADO.

Como referencia general, la selección de preprocesamientos a considerar se apoyó en fMRIPrep, que define su minimal preprocessing para fMRI en términos de motion correction, field unwarping, normalization, bias field correction y brain extraction. Sin embargo, no todos esos pasos se reprodujeron de forma completa en este estudio. En concreto, el trabajo se centró en una fase previa a la transformación a grafo orientada a estabilizar la señal, homogeneizar parcialmente la geometría y reducir parte del ruido antes de la GNN. Por ello, pasos como el motion correction real, la normalización espacial completa a MNI o la slice timing correction no deben considerarse plenamente implementados en este pipeline, mientras que sí lo están la lectura de metadatos, la estandarización geométrica básica, la normalización global de intensidad, el spatial smoothing y el band-pass.

ANEXO E: MODELO DE DECLARACIÓN DEL USO DE SISTEMAS DE IA

En la realización de este trabajo, se ha empleado inteligencia artificial **de manera responsable** en distintas fases del proceso. Para el análisis de la literatura, se utilizó en muy breves ocasiones la IA del propio navegador de Google, como asistente en consultas específicas sobre significados o explicaciones, garantizando siempre la verificación de fuentes.

En la fase de experimentación, se empleó Copilot de Visual Studio Code para crear ciertas funcionalidades previamente pensadas y definidas por mí cuando las ayudas, recursos de internet de estudios similares y mi conocimiento no bastaban para hacer lo que quería llevar a cabo en ese momento. Se utilizó también para detectar problemas que hacían que mi código dejase de funcionar y, de forma ajena a la línea de este PFG, como ayuda para desarrollar los tests del código de la librería desarrollada para poder alcanzar un coverage alto del programa. Se ha usado también para entender códigos de otras librerías y así ver si tenía sentido incorporarlo en la librería desarrollada en este PFG.

Finalmente en la redacción del documento, se utilizó principalmente el Copilot de Word como asistente en detección de ambigüedades o incoherencias con lo mencionado y corrección de algunas expresiones en función del contexto y de expresiones en forma personal (ya que se debe redactar todo en forma impersonal), aunque para el estado del arte sí que se hizo un mayor uso de IA, por lo que utilicé Gemini 2.0 Pro para verificación y validación de los informes y ayuda en la redacción de los mismos, y aunque tras las correcciones ha cambiado considerablemente, he dejado como referencia el enlace a dicha conversación.

En todo momento, **se ha mantenido el criterio académico y se ha supervisado que el uso de estas herramientas no comprometa la originalidad ni la calidad del trabajo.**

Contribución IA:

- Revisión de redacción: En todos y cada uno de los puntos del documento se ha utilizado Copilot de Word para revisar estructura, incoherencias y la forma impersonal. Cada vez que se terminaba un punto se ha lanzado el siguiente mensaje a dicho modelo: "Acabo de desarrollar el punto (número y título del punto desarrollado). Necesito que compruebes: primero, que se hable de forma impersonal? no puede poner por ejemplo "he hecho" o "hemos hecho", tiene que estar de forma impersonal todo, es decir, este ejemplo que te pongo debería aparecer como "se ha hecho". Y segundo, que no hay incoherencias o ambigüedades con lo mencionado previamente en el documento. Dedícale el tiempo que necesites para darme una respuesta, no hay prisa, priorizamos la calidad de la revisión".

- Como herramienta de búsqueda de varias opciones de datasets disponibles para el caso de uso trabajado. Posteriormente se analizaron a mano y se seleccionaron únicamente los realmente aptos.
- Ciertas funcionalidades de código, aunque la mayoría de las dudas pudieron resolverse preguntando a compañeros de trabajo o buscando en internet. Cabe mencionar que para todas estas ayudas se ha comunicado al modelo lo que debía hacer exactamente, no se ha dejado abierto a que el modelo aplicase lo que él quisiese, asegurando así que hacía lo esperado. Se ha recibido ayuda:
 - o En la parte de visualización de forma simétrica en la clase ModelMRIData de `eegraph/modelateData.py`.
 - o El mapa de nombres para los ROIs en `mrigraph/atlas.py`
 - o La función `_validate_transform_bundle` en `mrigraph/modelateData.py`
 - o Algunas líneas de código esparcidas por el código.
- Estado del Arte: para obtener una segunda validación de los informes previamente seleccionados por mí y como ayuda para redactar sobre ellos.
- Explicaciones/definiciones de conceptos que me he ido encontrando a lo largo del desarrollo del PFG, como puede ser atlas, los tipos de atlas, ROI, vóxel, los preprocesamientos, etc.